

VILNIAUS UNIVERSITETAS

MATEMATIKOS IR INFORMATIKOS FAKULTETAS

INFORMATIKOS STUDIJŲ PROGRAMA

Bakalauro baigiamasis darbas

LLM visuomenė: RAG grįstas personų kūrimas ir jų poveikis daugiaagentėje diskusijų sistemoje

LLM Society: RAG based persona creation and their impact in a multi–agent discussion system

Simonas Jaunius Urbutis

Darbo vadovas : prof. dr. Aistis Raudys

Vilnius
2026

This thesis presents an experimental agent-based discussion system using large language models (LLMs), in which agents are assigned personas generated by a RAG-based (Retrieval-Augmented Generation) module that draws on information collected from the web about a given discussion topic. This RAG-based method is compared with a baseline method, which relies only on information encoded in the model weights. The study was conducted using two topics relevant to the Lithuanian context and two LLMs differing in architecture and parameter count. The results show that the RAG-based method creates more diverse personas; however, this difference does not produce a measurable effect on agents' voting behavior – the dominant factor shaping the discussion dynamics remains the combination of the model and the topic.

Keywords: large language models, multi-agent systems, RAG, society simulation, discussion systems, agent persona generation, LLM bias

Santrauka

Šiame darbe sukurta eksperimentinė agentais paremta diskusijų sistema, naudojanti didžiuosius kalbos modelius (D.K.M.). Šioje sistemoje veikiantys agentai turi priskirtas personas, kurios yra kuriamos pasitelkiant RAG (angl. *Retrieval-Augmented Generation*) grįstą modulį su iš žiniatinklio surinkta informacija apie diskusijos temą. Šis RAG metodas palygintas su baziniu metodu, kuris agentų personų kūrimo metu remiasi tik modelio svoriuose užkoduota informacija. Tyrimas atliktas su dviem Lietuvos kontekstui aktualiomis temomis ir dvejais skirtingos architektūros bei parametrų skaičiaus D.K.M. Nustatyta, jog RAG metodas sukuria įvairesnes personas, tačiau šis skirtumas nesudaro išmatuojamo poveikio agentų balsavimo elgsenai – dominuojančiu diskusijos elgsenos veiksniu išlieka modelio ir temos kombinacija.

Raktiniai žodžiai: didieji kalbos modeliai, daugiaagentės sistemos, RAG, visuomenės simuliacija, diskusijų sistemos, agentų personų kūrimas, D.K.M. šališkumas

Turinys

Santrauka **3**

Įvadas **6**

1. Darbo tikslas **7**
1.1. Išsikelti uždaviniai 7

2. D.K.M. visuomenės simuliavimo galimybės ir ribos **8**
2.1. Visuomenės simuliavimo panaudojimas 8
2.2. Technologiniai D.K.M. apribojimai visuomenės nuomonių simuliavime 8
2.3. Sėkmingi D.K.M. taikymo atvejai 11
2.4. Nesėkmingi D.K.M. taikymo atvejai 11
2.5. Perėjimas nuo visuomenės simuliavimo prie agentų diskusijų 12

3. RAG grįstas agentų personų kūrimas **15**
3.1. RAG metodas 15
3.2. Žiniatinklio panaudojimas kartu su RAG 16

4. Bazinė diskusijų simuliacijos sistema **17**
4.1. Programinė įranga 17
4.1.1. D.K.M. agentų kūrimo bei valdymo biblioteka 17
4.1.2. Išvadų darymo variklis (angl. *Inference Engine*) 18
4.2. Sistemos architektūra 18
4.3. Atminties sistema 21
4.3.1. Ilgalaikės atminties funkcionalumas 21
4.4. Balsavimo funkcionalumas 24
4.5. Įvestis 26
4.6. Išvestis 26

5. Sistemos išplėtimas **28**
5.1. Sistemos architektūros pakeitimai 28
5.2. Programinė įranga 29
5.2.1. Žiniatinklio paieška – *„Tavily“* 29
5.2.2. Debesijos D.K.M. prieiga – *„OpenRouter“* 29
5.3. RAG personų kūrimo modulio įgyvendinimas 30
5.3.1. Paieškos užklausų planavimas 31
5.3.2. Žiniatinklio paieška 31
5.3.3. Pozicijų ir argumentų išgavimas 32
5.3.4. Požiūrio taškų dublikatų šalinimas 32
5.3.5. Personų atranka pagal schemą 33
5.3.6. Papildomos informacijos apie šaltinį gavimas 33
5.3.7. Personų sudarymas 34
5.4. Bazinis personų kūrimas 35
5.5. Balsavimo funkcionalumo pakeitimai 36
5.6. Vertinimo modulis 37
5.6.1. Personų vertinimas 37
5.6.2. Balsavimo vertinimas 39

6. Tyrimas **42**
6.1. Pasirinktos temos 42
6.2. Naudojami modeliai 43
6.2.1. Didieji kalbos modeliai 43
6.2.2. Sakinių įterpinių modelis 43
6.3. Pirmasis etapas – personų palyginimas 43
6.3.1. Metodologija 44
6.3.2. Rezultatai 45
6.3.3. Išvados 48
6.4. Antrasis etapas – diskusijų ir balsavimo analizė 48
6.4.1. Metodologija 48
6.4.2. Rezultatai 50
6.4.3. Išvados 56

7. Išvados **58**

8. Apribojimai ir ateities perspektyvos **60**

1 priedas. Programos kodas **63**

Įvadas

Pastaraisiais metais sparčiai didėjant didžiųjų kalbos modelių (D.K.M.) taikymui, vis aktyviau ieškoma naujų panaudojimo sričių, kurios išeitų už pokalbių asistentų, kodo rašymo ar kitų teksto kūrimo užduočių ribų. Viena tokių krypčių – visuomenės ir jos elgsenos modeliavimas: socialinio mokslo pasaulyje simuliacijos jau seniai naudojamos kaip įrankis vertinti ir prognozuoti žmonių tarpusavio bei su aplinka susijusias sąveikas. Tuo tarpu spartus D.K.M. technologinis tobulėjimas atveria galimybę kurti agentus, gebančius daug efektyviau valdyti natūralią kalbą, reaguoti į kontekstą bei keisti savo elgseną simuliacijų eigoje ir tai potencialiai daryti geriau nei iki šiol naudoti metodai. Vis dėlto, ar D.K.M. taikymas šioje srityje iš tikrųjų suteikia pridėtinės vertės, ar tėra dėl itin didelio susidomėjimo atsiradęs šalutinis efektas – kol kas tai lieka atviru klausimu.

Viena esminių visuomenės funkcionavimo dalių yra bendravimas – nuomonių formavimasis, argumentų mainai ir kolektyvinių sprendimų priėmimas. Todėl šiame darbe apžvelgiama diskusijų sistema gali būti naudojama kaip dalinis visuomenės atspindys arba kaip platesnės simuliacijos modulis. Vis dėlto, kuriant tokias sistemas, susiduriama ne tik su technologiniais D.K.M. apribojimais – šališkumu, faktiniais netikslumais ar polinkiu vengti konflikto – bet ir su praktiniu klausimu, kaip užtikrinti, jog agentai su priskirtomis personomis atspindėtų realius, su tema susijusius asmenis ar suinteresuotas šalis ir ar modelio svoriuose užkoduotų reikšmių ir santykių pakanka?

Šiame darbe yra nagrinėjamas D.K.M. taikymas kuriant agentais paremtą diskusijų sistemą, kurioje agentų personos yra kuriamos pasitelkiant RAG (angl. *Retrieval-Augmented Generation*) metodą – t. y. remiantis iš žiniatinklio (angl. *World Wide Web*) surinkta informacija apie diskusijos temą, o ne vien modelio svoriuose užkoduotomis žiniomis.

1. Darbo tikslas

Šio darbo pagrindinis tikslas – sukurti ir įvertinti agentais paremtą diskusijų sistemą, naudojančią didžiuosius kalbos modelius, kurioje agentams yra priskiriamos personos, sukuriamos pasitelkiant RAG (angl. *Retrieval-Augmented Generation*) grįstą personų kūrimo modulį, remiantis iš žiniatinklio surinkta informacija apie diskusijos temą. Sistema kaip įvestį gauna diskusijos temą bei pozicijų schemą, o kaip išvestį grąžina temai aktualių, suinteresuotųjų šalių diskusija bei jų balsavimo rezultatus diskusijos metu.

Darbe kuriama sistema yra skirta naudoti kaip eksperimentinė aplinka, leidžianti praktiškai palyginti RAG grįstą ir bazinį (be žiniatinklio paieškos) personų kūrimo metodus, bei įvertinti, kaip jų skirtumai atsispindi sukurtose agentų personose ir jų balsavimo elgsenoje. Atliekant tokį palyginimą siekiama nustatyti, ar žiniatinklio kontekstu grįstas personų kūrimas sudaro pastebimą skirtumą lyginant su analogišku metodu – pasitelkiant tik modelio svoriuose užkoduotomis vertėmis.

Be sistemos realizavimo, darbe taip pat siekiama išanalizuoti mokslinę literatūrą ir pagrindinius su tokio pobūdžio sistemomis susijusius techninius sprendimus – personų kūrimo proceso žingsnius, vertinimo kriterijų parinkimą ir D.K.M. modelio bei pozicijų schemos poveikį galutiniam rezultatui.

1.1. Išsikelti uždaviniai

Siekiant įgyvendinti išsikeltus tikslus, buvo suformuluoti šie uždaviniai:

1. Išanalizuoti esamų D.K.M. simuliacijų bei personas taikančių sistemų kūrimo, vertinimo bei panaudojimo metodiką šaltiniuose.
2. Sukurti agentais paremtos personų diskusijų sistemos architektūrą, leidžiančią valdyti diskusijos eigą bei agentų tarpusavio sąveiką.
3. Išanalizuoti galimus vertinimo kriterijus ir sukurti minėtos sistemos vertinimo modulį.
4. Atlikti eksperimentus su skirtingomis sistemos įvestimis, konfigūracijomis bei D.K.M. modeliais ir įvertinti, kaip tai veikia agentų personomis grįstos diskusijos eigą, balsavimo pozicijų kaitą ir pasiskirstymą.

2. D.K.M. visuomenės simuliavimo galimybės ir ribos

Analizuojant literatūrą, galima pastebėti, jog D.K.M. taikymas visuomenės simuliacijos srityje turi potencialo ir gali demonstruoti įtikinamą elgesį, panašų į žmogišką, kaip teigia darbo [POC+23] autoriai. Nepaisant to, kiti šaltiniai, kaip darbo [WWJ+25] autoriai, oponuoja šiam teiginiui ir aprašo įgimtus D.K.M. bei tokio pobūdžio sistemų įgyvendinimo trūkumus. Šiame skyriuje aptariama tokių simuliacijų teikiama nauda socialiniuose moksluose, pagrindiniai technologiniai apribojimai, sėkmingi ir mažiau sėkmingi taikymo atvejai bei perėjimas prie šiame darbe tiriamos diskusijų sistemos.

2.1. Visuomenės simuliavimo panaudojimas

Įvairiose socialinių mokslų šakose, o ypatingai sociologijoje, skaitmeninės visuomenės simuliacijos kartu su sociologijos ekspertų žiniomis neretai yra naudojamos kaip vienas iš įrankių vertinant įvairių socialinių fenomenų susikūrimą, priežastis bei pasekmes. Kaip teigiama [SJE14], esamos simuliacijos negali tiksliai pavaizduoti realaus pasaulio, bet suteikia užtektinai informacijos geriau vertinti pasaulinius įvykius ir jų valdymo galimybes. Ir nors pritaikymo sritis yra labai plati, daugiausiai analizuojami politikos, ekonomikos ir verslo pasauliai bei žmonių įsitikinimai ar sąryšiai su bendruomene. Šių simuliacijų pagalba galima vertinti tokius įvykius kaip komunizmo sistemų griūtis, karo konfliktus bei finansinės krizes. Anot darbo [SJE14] autorių, neretai tokios sistemos padeda geriau apžvelgti ir mikro lygio socialines sąveikas tarp individus reprezentuojančių agentų, kurie galiausiai tampa pasekmėmis platesnio masto įvykiams. Kaip pavyzdį [SJE14] darbo autoriai naudoja ekonomikos rinką, kurią socialinio mokslo ekspertai savo tyrimuose pasitelkia kaip vieną pagrindinių, kiekybiniu įrankiu socialiniams fenomenams aiškinti, bet krizės atveju rinka neretai elgiasi neprognozuojamai, todėl toks vertinimas reikalauja socioekonominio stabilumo siekiant gauti kokybiškų įžvalgų. [SJE14] Tokiose situacijose neretai atsiranda labai daug ekspertų su dar daugiau nuomonių bei sprendimo būdų. Visuomenės modeliavimas gali padėti įvertinti tokių scenarijų kilmę bei pasekmes itin socialiai ir ekonomiškai kompleksiškose aplinkose kaip mūsų pasaulis.

Šiame darbe tiriama pagalbinė sistema, kuri galėtų veikti kaip vienas iš platesnės simuliacijos modulių - tai aptariama vėlesniuose skyriuose. Nepaisant to, daroma prielaida, jog panaudojimo sritis yra stipriai susijusi ir dalinai persidengia.

2.2. Technologiniai D.K.M. apribojimai visuomenės nuomonių simuliavime

D.K.M. agentų pagrindu kuriamos simuliacijos sistemos turi įgimtų problemų, kurios mažina jų kokybę ir apsunkiną implementaciją. Šiuos trūkumus bei problemas straipsnyje [**wang2025limits**] autoriai skirsto pagal jų prigimtį. Jų teigimu, jos kyla arba iš naudojamų D.K.M. arba pačios simuliacijos sistemų įgyvendinimo metu priimtų pasirinkimų.

Iššūkiai, kylantys dėl D.K.M. yra įgimti technologijai ir kyla iš jų architektūros sprendimų ar apmokymui skirtų duomenų trūkumų.

1. **D.K.M. šališkumas**

   Nepaisant to, jog naujuose kalbos modeliuose yra dedama daugiau pastangų mažinti šališkumą, darbo [KJA+24] autoriai ištyrę 50 modelių įvertino, jog jie yra dar labiau šališki negu jų senosios versijos. Papildomai buvo pastebėta, jog kuo daugiau parametrų turi modelis, tuo daugiau šališkumo požymių pastebima. Straipsnio [WWJ+25] autoriai teigia, jog būtent lyties, kultūrinis bei profesinis šališkumas labiausiai kenkia simuliacijoms ir trukdo užtikrinti aukštesnę rezultatų kokybę. Dėl šios ypatybės agentų veiksmai simuliacinėse sistemose gali būti klaidingai kuriami pagal mokymo duomenų stereotipus, nors yra siekiama, jog jie atsirastų iš simuliacijos taisyklių bei agento atminties ir asmenybės. Nepaisant to jog lentelėje 1 dauguma iš 50 įvertintų D.K.M. pasižymi šališkumo vertinimu, kuris yra didesnis negu 60 % galime pastebėti ir modelių serijų kaip „Google Gemma-2“, kur kai kurie šios šeimos modeliai neviršija ir 6% ribos. Darbo [KJA+24] autoriai teigia, jog toks rezultatas buvo pasiektas naudojantis papildomu mechanizmu modelio architektūroje, kuris vertindamas įvesties dalių svarbumą (angl. attention) remiasi tiek plačia, prieš tai išmokta informacija, tiek siauresne, pateiktame kontekste egzistuojančia, informacija. Siekiant padidinti simuliacijos kokybę reikėtų remtis šių modelių mokymosi metodais bei šališkumo mažinimo praktikomis norint pasiekti aukštesnius rodiklius.

Provider	Model Name	IAT Bias Score (%)	Decision Bias Score (%)	Avg. Bias Score (%)
Meta	Meta-Llama-3.1-8B-Instruct	53.70	73.78	63.74
	Meta-Llama-3-8B-Instruct	72.83	72.89	72.86
	Llama-2-7B-chat-hf	38.89	40.44	39.67
	Llama-2-7B-Chat-GGUF-8bit	43.21	28.00	35.60
	Llama-2-7B-Chat-GGUF-4bit	46.30	27.11	36.70
	Llama-2-13b-chat-hf	61.72	91.11	76.42
	Meta-Llama-3.1-70B-Instruct	89.50	91.78	90.64
	Meta-Llama-3-70B-Instruct	89.50	86.67	88.08
	Llama-2-70b-chat-hf	71.60	90.22	80.91
	Meta-Llama-3.1-405B-Instruct-FP8	76.54	76	76.27
OpenAI	o1-preview	29.01	56.89	42.95
	o1-mini	60.49	84.89	72.69
	GPT-4o-mini	92.59	100	96.29
	GPT-4o	67.28	95.56	81.42
	GPT-4-0125-preview	28.39	90.22	59.31
	GPT-4-turbo-20204-04-09	43.21	94.67	68.94
	GPT-3.5-turbo	98.15	**99.11**	**98.62**
Google	Gemma-2-9b-it	**0.62**	71.11	35.86
	Gemma-2-27b-it	12.34	**0**	**6.17**
	Gemma-7b-it	68.51	83.56	76.03
Mistral	Mistral-7B-Instruct-v0.1-GGUF-8bit	38.27	86.67	62.47
	Mistral-7B-Instruct-v0.1-GGUF-4bit	42.59	91.55	67.07
	Mistral-7B-Instruct-v0.2-GGUF-4bit	80.25	88.00	84.12
	Mistral-7B-Instruct-v0.2-GGUF-8bit	87.04	92.89	89.96
	Mistral-7B-Instruct-v0.2	90.74	91.11	90.92
	Mistral-7B-Instruct-v0.3	89.51	98.22	93.86
	Mixtral-8x22B-Instruct-v0.1	79.63	87.55	83.59
	Mixtral-8x7B-Instruct-v0.1	83.95	87.11	85.53
Anthropic	Claude-3.5-Sonnet-20240620	38.89	73.78	56.33
	Claude-3-Opus-20240229	24.69	72.89	48.79
	Claude-Instant-1.2	43.82	96	69.91
	Claude-3-Haiku 20240307	83.33	93.78	88.56
Rakuten	RakutenAI-7B-chat	66.05	55.11	60.58
	RakutenAI-7B-Instruct	83.33	81.77	82.56
Qwen by Alibaba	Qwen1.5-14B-Chat	78.39	95.55	86.97
	Qwen-2-7B-Instruct	87.65	84.44	86.05
	Qwen-2-72B-Instruct	77.16	98.67	87.91
	Qwen-2-57B-A14B-Instruct	**99.38**	89.33	94.36
Microsoft	Phi-3-medium-128k	59.11	93.83	76.47
	Phi-3-medium-4k	96.29	95.11	95.70
	Phi-3-mini-4k-Instruct	86.41	86.67	86.54
	Phi-3-small-128k-instruct	88.27	93.77	91.02
	Phi-3-mini-128k-instruct	92.59	93.33	92.96
	Phi-3-small-8k-instruct	93.83	95.56	94.69
Allen AI	OLMo-7B-Instruct	56.17	75.56	65.86
Abacus AI	Smaug-Llama3-70B-Instruct	69.75	97.78	83.77
	Smaug-72B-v0.1	83.33	95.55	89.45
	Smaug-34B-v0.1	97.53	96.44	96.99
Jamaba	Jamaba-Instruct-preview	73.46	84.44	78.95
Cohere	Aya-23-8b	92.59	90.22	91.41
	Aya-23-35B	92.59	95.11	93.85
	c4ai-command-r-plus	69.13	94.67	81.90
Databricks	DBRX-instruct	85.80	88.00	86.90
Snowflake	Snowflake-arctic-instruct	98.15	96.44	97.29

1 pav. *D.K.M. šališkumo vertinimo lentelė [KJA+24]*

2. **D.K.M. skirtingas „protavimo“ mechanizmas**
   Darbo autoriai [WWJ+25] taip pat teigia, jog dabartiniai modeliai nesugeba „mąstyti žmogiškai“: išlaikyti nuoseklaus protavimo priimant sprendimus, vertinti emocinį svorį ar užtektinai efektyviai prisitaikyti prie naujos informacijos. Papildomai dėl atminties ribojimų modeliuose, simuliacijos sistemose agentai nesugeba pilnavertiškai atspindėti žmogaus atminties bei potyrių mechanizmo. Straipsnyje [PS24] autoriai ištyrė modelio *„GPT-4“* sugebėjimą pažinti naują informaciją ir įvertino modelio gebėjimus atkartoti mokymosi medžiaga skirtingomis formomis ir įvertinti ar modelis „supranta“ tai ką jis pateikia išvestyje. Pateikdami įvairias internete išpopuliarėjusias puzles darbo autoriai nustatė, jog nekeičiant puzlių formuluotės modelis su jomis susitvarkė nepriekaištingai, bet pakeitus kelis atsitiktinius elementus užduoties jis jos nebe sugebėjo atlikti, kas leidžia suprasti, jog tariamas „modelio loginis suvokimas“ nėra pakankamas pilnavertiškai išspręsti duotosioms puzlėms. Šioms problemoms išspręsti [WWJ+25] straipsnyje siūloma naudoti išskaidytą architektūrą, kurioje atskiri moduliai būtų atsakingi už skirtingas kognityvines funkcijas – planavimą, samprotavimą ir emocijų apdorojimą – taip didinant agentų elgsenos pastovumą ir simuliacijos patikimumą.

Šalia „įgimtų“ D.K.M. problemų, pasiekti aukštesnę kokybę trukdo ir simuliacinių sistemų įgyvendinimo trūkumai, kurie nekyla tiesiogiai iš D.K.M., o verčiau iš įvairių technologinių ir architektūrinių sprendimų, kuriuos priima šių sistemų autoriai.

1. **Pernelyg primityvus suvokimas apie tai kaip veikia žmogus**
   Kuriant šias, žmonių sąveiką atspindinčių sistemų architektūras, neretai galimos žmogaus emocinės būsenos yra verčiamos į skaičių skales ar kategorijas – visą žmogaus gyvenimo patirtį sutraukiant į pamatuojamus veiksmus, neatsižvelgiant į asmeninę ar aplinkos raidą. Taip pat yra kuriami pernelyg primityvūs paskatų mechanizmai, kurie neatsižvelgia į visą asmeninių, socialinių bei kultūrinių įtakų spektrą. Šioms problemoms spręsti darbo [WWJ+25] autoriai rekomenduoja kurti sistemą, kurioje kiekvienas žmogų atspindinčio agento elementas, kaip atmintis ar planavimas, būtų įgyvendinamas kaip atskiras modulis. Šį modulį būtų galima vertinti nepriklausomai nuo kitų, bei ieškoti būdų kaip šiuos žmogaus elementus įgyvendinti kiek kompleksiškiau. Papildomai reikėtų nuolat stebėti ir vertinti agentus ir simuliaciją bei sukurti dinamiškai kintančią kelių dimensijų paskatų sistemą.

2. **Neefektyvūs vertinimo metodai**
   Dabartinėse simuliavimo architektūrose vertinimo sistemos yra per paprastos ir susiduria su prieš tai minėta problema, jog vertinimas neaprėpia žmogaus protavimo kompleksiškumo. Be to, esami vertinimo mechanizmai nesugeba realiu laiku kisti ir prisitaikyti prie simuliacijos būsenos bei efektyviai integruoti simuliuojamo scenarijaus ekspertų žinių, išlaikant žmonių sąveikavimo kompleksiškumą. Šioms problemoms spręsti, straipsnyje [WWJ+25] yra siūloma sukurti realaus laiko hierarchines vertinimo sistemas kartu su architektūromis, kurios leistų lanksčiai pritaikyti ekspertų žinias pagal tiriamą sritį.

2.3. Sėkmingi D.K.M. taikymo atvejai

Nepaisant aptartų apribojimų, literatūroje galima rasti atvejų, kuomet D.K.M. grįstos simuliacijos pasiekia gerų rezultatų – paprastai tada, kai simuliuojama aplinka yra aiškiai apibrėžta, o vertinimo kriterijai patikrinami empiriškai.

Vienas iš pavyzdžių, demonstruojančių šios srities potencialą, yra vartotojų elgsenos tyrimas, kuriame [MAF+25] autoriai tyrė galimybę panaudoti D.K.M. siekiant imituoti apklausas apie vartotojų polinkį pirkti produktus. Šiame tyrime D.K.M. pagalba buvo sukuriamos sintetinių vartotojų personos, kaip įvestį pateikiant demografinį profilį – amžių, pajamų lygį ir kitus socialinius parametrus – bei pateikiant apklausoje aptariamo produkto aprašymą. Šiems sintetiniams vartotojams buvo pateikiami tie patys apklausos klausimai, kuriuos gavo ir tikri respondentai – atsakymai buvo gaunami tiesiogiai iš modelio, kurio įvestyje buvo nurodyta apsimesti atitinkamo demografinio profilio vartotoju. Tuomet autoriai palygino tris atsakymų gavimo metodus:

- **tiesioginį skaičių skalės vertinimą** (angl. *Direct Likert Rating*, DLR) – gaunamą nurodant modeliui tiesiogiai pateikti skaitinį įvertinimą apie polinkį pirkti.
- **dviejų žingsnių vertinimą** (angl. *Follow-up Likert Rating*, FLR) – gaunamą nurodant vienam modeliui pateikti tekstinį atsakymą, o vėliau nukreipiant šį atsakymą į kitą modelį, kuris tekstinį atsakymą paversdavo skaitine reikšme.
- **semantiniu panašumu grįstą vertinimą** (angl. *Semantic Similarity Rating*, SSR) – gaunamas laisvos formos tekstinį atsakymą paverčiant įterpiniais (angl. *embeddings*) ir lyginant su atskaitos frazėmis kiekvienai Likerto skalės reikšmei – skalės vertė priskiriama pagal didžiausią kosinuso panašumą.

Tiesioginis DLR metodas demonstravo labai siaurą atsakymų pasiskirstymą, kuriame modeliai beveik niekada nesirinkdavo ekstremumų – kas stipriai skyrėsi nuo realių respondentų atsakymų. FLR metodas pasiekė daug didesnę pasiskirstymo sutapimo metrikos rodiklį – 0,59-0,72, o SSR metodas 0,8-0,88 vietoje 0,26-0,39, kurį pasiekė pirmasis metodas. Svarbu pabrėžti, jog šis sėkmingas atvejis naudoja įvesties duomenis, kurie apibrėžia JAV rinką, bei sistemoje keliamas klausimas yra ganėtinai siauras ir gerai apibrėžtas.

2.4. Nesėkmingi D.K.M. taikymo atvejai

Vis dėlto ne visi tyrimai demonstruoja tokius pat rezultatus. [GHT24] autoriai tikrino, ar D.K.M. gali imituoti Europos socialinio tyrimo (angl. *European Social Survey*, ESS) respondentų atsakymus – ir nors JAV kontekste atlikti panašūs tyrimai parodė gerus rezultatus, Europos kontekste jie buvo ženkliai prastesni.

Simuliacijoje, panašiai kaip ankščiau aptartame darbe, buvo formuojami sintetiniai respondentai, pagal demografinius duomenis surinktus apklausose – lytį, gimimo metus, šalį ir profesijos ka-

tegoriją. Šiems respondentams buvo pateikiami tie patys apklausos klausimai, kuriuos gavo ir tikri respondentai. Atlikę tyrimus, autoriai pateikė šias išvadas:

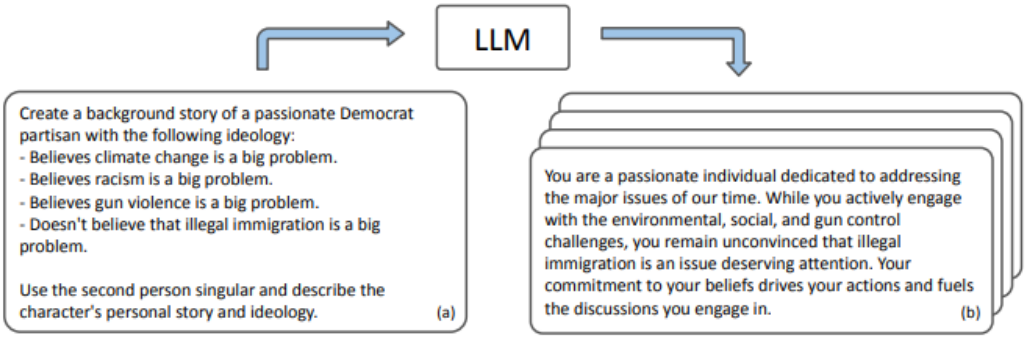
- Vienoms respondentų grupėms simuliacija sugebėjo atkurti panašius vidutinius atsakymus, tačiau bendras atsakymų pasiskirstymas dažniausiai nesutapo, buvo mažesnis lyginant su realiais respondentais.
- D.K.M. pasirinkimas, jų užklausos kūrimo parametrai (angl. inference hyperparameters) bei modelio įvestys (angl. prompts) turėjo didelę įtaką rezultatams, todėl svarbu įvertinti ir šį faktorių atliekant panašaus tipo tyrimus. Taip pat buvo teigiama, kad modeliai demonstravo ryškų polinkį pateikti vidutinės reikšmės atsakymus – rečiau teikdavo kraštutinius.
- Pastebima, jog jei sintetiniams respondentams yra suteikiama daugiau demografinių duomenų, jų atsakymai dažniau sutampa su realiais respondentais, lyginant su mažesniu duomenų kiekiu.
- Galiausiai buvo pastebimas šališkumo tendencingumas, kuomet kai kurių šalių sintetiniai respondentai demonstravo itin prastus rezultatus. Šis fenomenas sutapo ir su pačių autorių nagrinėtais šaltiniais, kur ta pati situacija buvo matoma ir tyrimuose su mažesnėmis respondentų grupėmis JAV kontekste.

Apibendrinant tyrimo rezultatus, autoriai teigia, jog apklausų rezultatų simuliavimas pasitelkiant D.K.M. nėra visiškai nepagrįstas metodas, bet šiuo metu bendri rezultatai, o ypač tokios detalės kaip pasiskirstymas yra prasti.

2.5. Perėjimas nuo visuomenės simuliavimo prie agentų diskusijų

Vertinant iki šiol aptartus šaltinius, galima pastebėti bendrą tendenciją: D.K.M. grįstos simuliacijos turi potencialo, bet šiuo metu negali būti laikomos pilnavertišku įrankiu simuliuoti visuomenės procesams. Šis teiginys glaudžiai susijęs su pačių modelių apribojimais: šališkumu, nepakankama elgesio įvairove ar jo sutapimu su žmonių elgesiu bei su modelių negebėjimu reprezentuoti mažesnių populiacijos grupių.

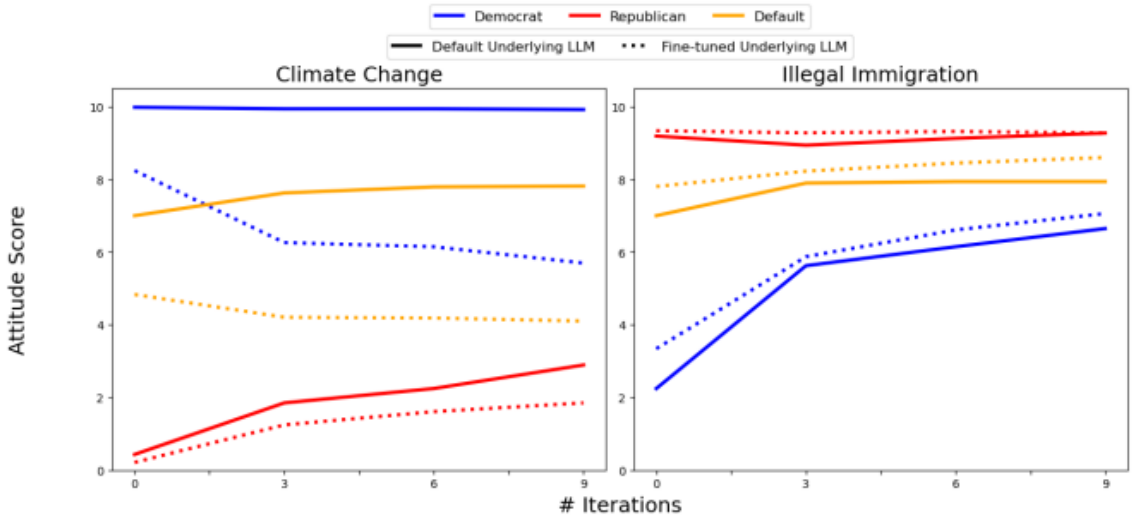
To pasekoje, šiame darbe buvo priimtas sprendimas tirti D.K.M. pagalba sukurtų personų elgesį ir sąveiką neprilyginant jų realiems žmonėms. Norint įgyvendinti tokio pobūdžio tyrimą, buvo nuspręsta kurti agentų diskusijos sistemą, kuri ateityje galėtų veikti ir kaip vienas iš platesnės simuliacijos modulių. Šis sprendimas iš dalies remiasi šaltinio [TDR+24] atliktu tyrimu, kuriame buvo tirta, ar D.K.M. agentai geba išlaikyti jiems priskirtas politines pozicijas. Tyrime agentų personos buvo kuriamos D.K.M. pagalba sukuriant biografinius aprašus, atitinkančius politinę tapatybę (demokrato ar respublikono) – panašiu principu kaip ankščiau aptartuose darbuose sintetiniams respondentams buvo suteikiama demografinė informacija. Šį procesą ir jo rezultato pavyzdį galima matyti 2 pav.



2 pav. *Personos kūrimo procesas ir sukurto personos aprašo rezultatas [TDR⁺24]*

Tuomet šios personos tarpusavyje dalyvavo diskusijoje pagal pateiktą temą. Debatų metu agentų pozicijos apie duotą temą buvo stebimos taikant interviu metodą: agentams periodiškai buvo užduodami klausimai, skirti išreikšti jų politinėms pažiūroms, o gauti atsakymai buvo naudojami stebėti nuomonių pokyčius debatų sesijos metu. Svarbu paminėti ir tai, jog autoriai, siekdami patikrinti, ar šališkumas kyla iš paties modelio, o ne iš simuliacijos dizaino, papildomai atliko dar vieną eksperimentą. Šio eksperimento metu buvo papildomai ištreniruotas (angl. finetune) bazinis D.K.M. naudojant pačių agentų sintetiniu būdu sugeneruotus duomenis siekiant pakeisti modelio šališkumą. Taip pat svarbu paminėti, jog eksperimento metu buvo įtrauktas ir „nešališkas“, neutralus agentas, kuriam vietoj politinės tapatybės modelio įvestyje buvo pateikiama vienintelė instrukcija: *„Tu esi amerikietis“* – t.y. agentas, kurio persona neturi jokios aiškios politinės „nuomonės“.

Šių eksperimentų rezultatai vaizduojami 3 pav., kuriame matomi agentų požiūrio pokyčiai klimato kaitos ir nelegalios imigracijos temomis – tiek prieš modelio papildomą treniravimą (ištisinės linijos), tiek po jo (punktyrinės linijos).



3 pav. *Agentų požiūrio pokyčiai debatų eigoje prieš ir po bazinio modelio papildomo treniravimo [TDR⁺24]*

Tyrimo rezultatai atskleidė kelis svarbius dėsningumus. Pirma, trijų agentų debatuose – kuriuose dalyvavo respublikoną, demokratą ir nešališką agentą atstovaujantys dalyviai – nešališkas

agentas išlaikė stabilią poziciją, o kiti agentai palaipsniui priartino savo pažiūras. Tai rodo, jog „nešališkas“ agentas veikė kaip bazinio modelio šališkumo atspindys, o kitų personų agentai nesugebėjo jam pasipriešinti. Antra, pašalinus nešališką agentą ir palikus tik du politines nuomones turinčius agentus, konvergacijos reiškinys išliko, kas patvirtino, jog jo šaltinis yra modelio svoriuose užkoduotas šališkumas, o ne kito agento tiesioginė įtaka pokalbyje. Trečia, vienos partijos debatuose – pvz. tarp dviejų respublikonų – agentai elgėsi priešingai nei žmonės: vietoj to, kad sustiprintų savo nuomones, kaip tai nutinka realiuose burbulų efekto (angl.*echo chamber*) situacijose, agentai tapo nuosaikesni ir vėl artėjo prie modelio šališkumo centro, net jei tai ir prieštaravo aprašytoms pozicijoms. Ketvirta, papildomai treniruoto modelio eksperimento metu, nors agentų personų aprašai liko nepakeisti, jų pozicijos debatuose pasikeitė pagal treniravimo metu nustatytą naują šališkumą. Penkta, nuomonių pokyčių intensyvumas mažėjo diskusijos eigoje – reikšmingiausi pokyčiai buvo stebimi pirmaisiais debatų etapais, o vėlesniuose pokyčiai tapo minimalūs.

Šio darbo pagrindine išvada tapo pastebėtas dėsningumas, kur modelio svoriuose užkoduotas šališkumas yra pagrindinis veiksnys lemiantis agentų elgseną nepriklausomai nuo jiems priskirtų personų ar debatų struktūros.

3. RAG grįstas agentų personų kūrimas

Įvertinus D.K.M. grįstą personų diskusijų simuliavimą šaltiniuose, buvo nuspręsta nagrinėti, kokį poveikį skirtingi personų kūrimo metodai daro diskusijos eigai. Toks pasirinkimas kyla iš minėtos problematikos ir poreikio geriau suprasti tiek D.K.M., tiek pačios sistemos poveikį simuliacijos galimybėms. Didžiausią dėmesį skiriant šališkumo bei mažesnių demografijų reprezentacijos problematikai šioje srityje. Remiantis [TDR+24] atliktu eksperimentu, kuris parodė, jog agentų konvergacijos šaltinis yra modelio svoriuose užkoduotas šališkumas, o ne simuliacijos dizainas, šiame darbe keliama hipotezė, jog personos papildymas išoriniais šaltiniais grįstu kontekstu galėtų sušvelninti ar pakeisti šį reiškinį, nekeičiant paties modelio.

Viena iš galimų prieigų yra personos papildymas faktine informacija naudojant RAG metodą. [PC26] autoriai lygino D.K.M. elgseną su ir be RAG ir nustatė, jog išorinio konteksto įtraukimas sumažino šališkumą daugumoje iš 13 tirtų jo tipų. Remiantis šiais rezultatais, šiame darbe keliama hipotezė, jog RAG grįstos personos galėtų veikti kaip stipresnis kontekstinis pagrindas, mažinantis modelio svoriuose užkoduoto šališkumo įtaką diskusijos eigai. Nors [PC26] tyrimas vertina šališkumą klausimų-atsakymų sistemos kontekste, o ne daugiagentėje diskusijoje ir RAG metodas yra taikomas tiesioginei modelio išvesčiai, o ne personų kūrimui – siūlomas sprendimas yra analogiškas aukštesniu lygiu: išorinis kontekstas kaip atsvaras modelio svoriuose užkoduotam šališkumui.

Šiame darbe bus kuriama sistema, kurioje personų kūrimo procesas bus įgyvendinamas dviem būdais: naudojant RAG metodą bei sintetiškai kuriant agentų personų aprašymus naudojant D.K.M. be papildomų šaltinių. Tokiu būdu bus siekiama įvertinti, kokį poveikį skirtingi personų kūrimo metodai daro diskusijos eigai. Papildomai, tyrimui bus pasirenkamos Lietuvos demografijai aktualios temos – taip į analizę įtraukiant ir aptartą mažesnių demografijų reprezentacijos problematiką.

3.1. RAG metodas

RAG tai metodas, kuomet sistemos su D.K.M. prieš pateikdamos išvestį pirmiausia ieško papildomos informacijos (pvz., dokumentuose, duomenų bazėje ar internete), o tada naudoja ją atsakymui kurti. Remiantis straipsnio [GXG+23] autoriais, šis metodas padeda išspręsti D.K.M. integracijos problemas, kuomet yra poreikis modeliui suteikti informaciją, kuri yra visiškai nauja ir/ar nebuvo naudota pirminio treniravimo metu. Atsiradus *„chatGPT“* platformai buvo pastebėta, jog turimi modeliai sugeba mokytis ir atlikti užduotis iš pateikto konteksto (angl. in context learning), ko pasekoje išpopuliarėjo RAG metodo taikymas. Paprasčiausioje šio metodo įgyvendinimo formoje atliekami šie žingsniai:

1. **Indeksavimas** Norimi duomenys išvalomi ir konvertuojami į struktūrizuotą teksto formatą, pavyzdžiui, *Markdown*. Tuomet tekstas suskaidomas į mažesnius fragmentus (angl. *chunks*), kurie paverčiami įterpiniais (angl. embeddings) naudojantis įterpinių modeliu (angl. *embedding model*) ir patalpinami į vektorinę duomenų bazę.

2. **Paieška** Prieš pateikiant užklausą D.K.M. ji yra paverčiama įterpiniu, naudojant tą patį modelį, kuris buvo naudotas indeksavimo metu. Tuomet yra apskaičiuojamas panašumo vertinimas tarp užklausos vektoriaus ir indeksuotų fragmentų įterpinių, dažniausiai tai yra kosinusinis panašumas (angl. *cosine similarity*) arba euklidinis atstumas. Nustačius panašumą, yra išrenkami (angl. *Top K*) aukščiausią įvertinimą gavę fragmentai.

3. **Atsakymo generavimas** Atrinkti fragmentai sujungiami su pateikta užklausa sudarant vientisą D.K.M. įvestį. Tokiu būdu modelis pateikia atsakymą, remdamasis tiek žiniomis iš pradinio treniravimo, tiek pateikta nauja informacija.

3.2. Žiniatinklio panaudojimas kartu su RAG

Aptartas „klasikinis“ RAG metodas paprastai remiasi iš anksto indeksuotų dokumentų rinkiniu. Šiame darbe pasirinkta kita šio metodo variacija, kurioje duomenų rinkinys sudaromas iš žiniatinklio puslapių. Šis pasirinkimas buvo padarytas siekiant tyrimui skirtoje sistemoje sudaryti sąlygas tirti įvairias temas, bei buvo daroma papildoma prielaida, jog naujausia informacija gali turėti papildomą poveikį, lyginant su informacija, kuri buvo naudojama atliekant tyrime naudojamų D.K.M. treniravimą. Taip pat buvo papildomai įvertintas praktinis šios sistemos panaudojimas už tyrimo ribų, darant prielaidą, jog žiniatinkliu grįstas RAG metodas reikalauja mažiau pastangų naudoti bei palaikyti, nei „klasikinis“ RAG.

4. Bazinė diskusijų simuliacijos sistema

Tyrimui skirtos sistemos pagrindu tapo ankstesniame darbe sukurta sistema. Šios sistemos pagrindinis tikslas buvo modeliuoti diskusiją tarp kelių D.K.M. valdomų agentų, turinčių personos aprašymus ir įvertinti sukurtų diskusijų kokybę.

4.1. Programinė įranga

Bazinės sistemos įgyvendinimui naudota keletas pagrindinių programinės įrangos įrankių, kurie aprašomi toliau.

4.1.1. D.K.M. agentų kūrimo bei valdymo biblioteka

Kuriant D.K.M. naudojančias sistemas, ypač tokias, kurios turi sudėtingesnį D.K.M. panaudojimo atvejį ar įgyvendina agentų pagrindu veikiančią logiką, yra naudojamos programinės įrangos bibliotekos, skirtos kuruoti D.K.M. veikimą ir su jais susijusių resursų naudojimą. Remiantis *„IBM“* internetinio straipsnio [Pra] teiginiais, šios bibliotekos įgyvendina dažnai pasikartojančias D.K.M. funkcijas, tokias kaip konteksto valdymas, įrankių panaudojimas bei integracija su kitų technologijų bibliotekomis. Efektyviai naudodamiesi šiomis bibliotekomis, sistemų autoriai gali greičiau pasiekti norimą rezultatą ir daugiau dėmesio skirti aukštesnio lygio logikai projektuoti ir įgyvendinti.

Renkantis biblioteką, svarbu įvertinti:

1. Kokie D.K.M. yra palaikomi?
2. Kaip įgyvendintas pamatinis, logikos kuravimui skirtas funkcionalumas?
3. Kokiu būdu valdomas D.K.M. kontekstas ir atmintis viso veikimo metu?
4. Ar yra užtektinai plačios galimybės integracijai su kitomis technologijomis?
5. Ar bibliotekos vartotojui yra suteikiama pakankamai laisvės pritaikyti bibliotekos funkcionalumą savo išsikeltiems tikslams, bei diegti sistemą norimoje aplinkoje?
6. Ar bibliotekos palaikymo rodikliai užtikrina sklandų tolimesnį naudojimą?

Atsižvelgus į šiuos kriterijus bei straipsnio [Pra] išvadas, buvo pasirinkta *„LangGraph“* biblioteka. Šio pasirinkimo pagrindinė priežastis yra, anot straipsnio [Pra] autorių, platus šios bibliotekos taikymas tokiuose pažangiose programinės įrangos įmonėse, kaip *„Uber“*, *„LinkedIn“* ar *„GitLab“*, kas leidžia teigti, jog sistemos palaikymas yra užtektinai didelis, o pritaikymo galimybės plačios. Papildoma priežastis yra bibliotekos pamatinė koordinavimo struktūra, kurioje logika yra įgyvendinama grafo pavidalu ir gali būti atvaizduojama viršūnių bei briaunų struktūra, kas yra palanku kuriant diskusijų sistemą. Galiausiai ši biblioteka palaiko daugumą D.K.M. panaudojimo metodų, įskaitant lokaliai laikomų modelių panaudojimą, bei gali būti diegiama daugumoje aplinkų, pavyzdžiui, *„Linux“* ar *„Windows“*.

4.1.2. Išvadų darymo variklis (angl. *Inference Engine*)

Siekiant efektyviai išnaudoti D.K.M., yra naudojami išvadų darymo varikliai (angl. *Inference Engine*), kurie palengvina šių modelių panaudojimą, suteikdami patogią aplikacijų programavimo sąsają, leidžiančią nesunkiai naudotis modeliais. Papildomai šie varikliai naudoja įvairius procesorių bei vaizdo plokščių podelių (angl. *cache*) optimizavimo metodus, kuriais yra siekiama sutrumpinti užklausos apdorojimo laiką ir efektyviau naudoti sistemos resursus.

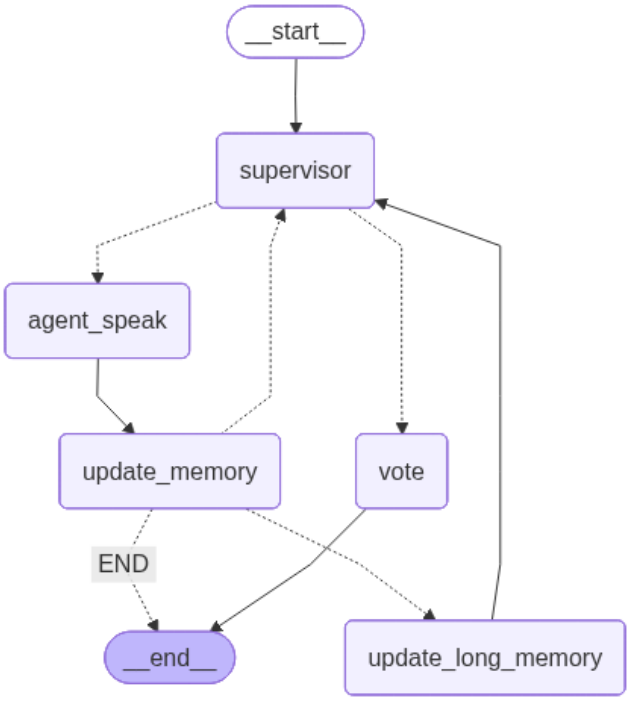
Šių variklių pasirinkimas yra itin platus, bet atsižvelgiant į darbo išsikeltus tikslus buvo vertinami tik keli kriterijai. Buvo nuspręsta, jog itin efektyvus resursų valdymas ir užklausų apdorojimo greitis nėra prioritetai, vietoj to, variklio naudojimas bei diegimas turėtų būti paprastas, modelių patalpinimas turėtų palaikyti lengvai prieinamą formatą. Taip pat buvo siekiama, jog variklyje turėtų būti galimybė modelio naudojamą atmintį išskaidyti per kelių vaizdo plokščių atmintį.

Atsižvelgus į darbo [PJL+25] rezultatus, kuriuos autoriai pateikė ištyrę dvidešimt penkis išvadų darymo variklius, buvo pasirinktas *„Ollama“* variklis. Jis patenkina lengvo diegimo bei naudojimo lūkesčius, taip pat palaiko „GGUF“ formatą, kuris yra lengvai prieinamas daugumoje modelių saugyklų (angl. *model repositories*). Nors tą patį siūlo ir kiti varikliai, kaip *„vLLM“* ar *„Hugging Face TGI“*, bet *„Ollama“* išsiskiria plačiausiu modelių palaikymu, bei dideliu atviro–kodo bendruomenės palaikymu platformoje *„GitHub“*. Svarbu paminėti, jog sistemos kūrimo bei tyrimo metu buvo naudojamas tiek aptartas lokalus D.K.M. panaudojimas tiek vėlesniuose skyriuose aptariamas D.K.M. panaudojimas per debesijos sąsaja.

4.2. Sistemos architektūra

Naudojantis *„LangGraph“* biblioteka, visa sistemos logika buvo realizuota grafo principu, kur kiekviena viršūnė atspindėjo vieną diskusijos etapą, atskirą jo dalį arba atliko pagalbinę funkciją, skirtą agentų veiklos koordinavimui. Simuliacija buvo suskirstyta etapais, o etapai žingsniais.

Siekiant išvengti papildomo sudėtingumo agentų tarpusavio bendravimo koordinavime, buvo nuspręsta sistemos grafo kūrimą pradėti nuo „prižiūrėtojo“ (*supervisor*) viršūnės. Šios viršūnės paskirtis – centralizuotai koordinuoti visų agentų veikimą, vietoj to, kad šią funkciją atliktų patys agentai tarpusavyje. Toks sprendimas suteikė daugiau lankstumo tolimesniam sistemos modifikavimui ir pritaikymui įvairesniems bendravimo scenarijams, nes agentų veikimo logika buvo aiškiai atskirta nuo koordinavimo mechanizmo. Galutinis sistemos grafas pavaizduotas 4 pav.



4 pav. *Agentų koordinavimo grafo iliustracija*

Apart „prižiūrėtojo“ viršūnės galima matyti ir agento veikimo viršūnes, kurios yra suskirstytos į kalbėjimo (`agent_speak`), balsavimo (`vote`) ir trumpalaikės bei ilgalaikės atminties atnaujinimo (`update_memory`, `update_long_memory`) viršūnes. Agento kalbėjimo viršūnėje yra formuojama D.K.M. užklausa, sudaryta iš dviejų dalių: sisteminės užklausos (angl. system prompt) ir vartotojo užklausos (angl. user prompt). Šis dviejų dalių užklausos metodas yra taikomas ir visose tolimesnėse sistemos D.K.M. užklausose.

- **Sisteminė užklausa (angl. system prompt)**

  Sisteminėje užklausoje pateikiama bendra, nekintanti informacija apie simuliacijos scenarijų, agento identitetą ir jo vaidmenį. Šiai, kaip ir visoms kitoms D.K.M. užklausoms sistemoje, yra naudojami iš anksto apibrėžti šablonai. Būtent šios sisteminės užklausos šablonas 1 yra taikomas visose to paties agento diskusijos etapuose.

```
You are {agent_name}.
Role: {agent_role_description}.

Traits (describe how you usually think and speak):
{trait_key}: {trait_value}
{trait_key}: {trait_value}

Speak naturally and conversationally, as if you are
interacting live with a group of peers.

- Use short, casual sentences.
- Let your tone be informal and relatable.
- React in a way that fits your personality: respond
  directly, shift topics, share a quick story, ask a
  question, or go off on a brief tangent.
- Show genuine opinions and feelings.
- If you don't know something, admit it or steer the
  conversation elsewhere.
- Never refer to yourself as an AI or mention any
  instructions or rules.
- Write ONLY your spoken -turndo not include
  descriptions, inner thoughts, or explanation.
- Engage directly with what others -argueacknowledge
  compelling points honestly; push back if you disagree.

Response format:
Write only what you would say out loud, as a single,
natural-sounding statement or brief exchange.
<...>
Reminder: Sound like a genuine, casual person in a
live peer conversation. Respond freely and naturally.

Write only what you say in this turn as {agent_name},
nothing else.
```

Įvesties šablonas 1: Sistemos įvesties šablonas agento kalbėjimo viršūnėje

- **Vartotojo užklausa (angl. user prompt)**

  Vartotojo užklausoje perduodama einamojo diskusijos etapo informacija: diskusijos tema, ilgalaikės ir trumpalaikės atminties turinys bei minimalūs stiliaus nurodymai. Trumpalaikė atmintis sudaroma iš paskutinių N diskusijos žinučių, kur N yra konfigūruojamas sistemos parametras, ir atnaujinama po kiekvieno kalbėjimo etapo atskiroje grafo viršūnėje (`update_memory`).

Siekiant sumažinti haliucinacijas tuščios atminties atveju, vartotojo užklausos šablonas skiriasi priklausomai nuo to, ar agentas kalba pirmą kartą. Pirmojo kalbėjimo atveju agentui pateikiamos instrukcijos pradėti pokalbį ir trumpai pristatyti savo reakciją į temą, kaip matoma šablone 2. Tolesniuose etapuose užklausoje pateikiama abiejų atminčių informacija su instrukcija tęsti pokalbį, kaip matoma šablone 3.

```
Debate topic: {debate_topic}

You are the first to speak.
As {agent_name}, start the conversation naturally:
greet the others briefly and share your initial
reaction to the topic.
Keep it casual and true to your character,
in 2-5 sentences.
Write only what {agent_name} says.
```

Įvesties šablonas 2: Vartotojo įvesties šablonas agento kalbėjimo viršūnėje (pirmas kalbėjimas)

```
Debate topic: {debate_topic}
{long_memory_section}
Recent conversation (most recent first):
{short_memory_list}

Now continue the conversation as {agent_name}:
Let your reply follow naturally from the situation
and your personality.
You can respond directly, shift the focus, tell a
short anecdote, ask something, or even introduce a
side thought, if that feels right to you.
Keep it to roughly 2-5 sentences, sounding like
a real person.
Write only what {agent_name} says.
```

Įvesties šablonas 3: Vartotojo įvesties šablonas agento kalbėjimo viršūnėje (tolesni etapai)

4.3. Atminties sistema

Agentų atmintis yra įgyvendinta dviejų, vienas kitą papildančių, ilgalaikės ir jau aptartos trumpalaikės atminties viršūnėmis.

4.3.1. Ilgalaikės atminties funkcionalumas

Vienas pagrindinių apribojimų kuriant agentais paremtą diskusijos simuliaciją yra ribotas konteksto dydis, kurį tenka valdyti tiek dėl D.K.M. konteksto lango (angl. context-window) apribojimų,

tiek dėl geresnio galutinio rezultato. Dėl šios priežasties trumpalaikė atmintis pirmame sistemos kūrimo etape buvo realizuota kaip slenkantis langas, kuriame laikomos tik paskutinės N diskusijos žinutės. Tačiau toks sprendimas reiškė, kad diskusijai tęsiantis dalis ankstesnių įvykių ir argumentų iškrenta iš agento *matomo* konteksto, o tai gali lemti nenuoseklias pozicijas, pasikartojimus ar nesugebėjimą remtis anksčiau išsakytomis įžvalgomis tiek diskusijos etapuose, tiek balsavimo metu. Šiai problemai spręsti buvo įgyvendintas ilgalaikės atminties funkcionalumas.

Ilgalaikė atmintis sistemoje yra saugoma kiekvienam agentui atskirai kaip santraukų seka grafo būsenos egzemplioriuje. Kitaip tariant, periodiškai yra sukuriamas trumpas apibendrinimas, kuris atspindi diskusiją iš konkretaus agento perspektyvos. Santraukų kūrimas vykdomas ne po kiekvienos žinutės, o pagal konfigūruojamą intervalą (kas K žingsnių), tokiu būdu sumažinant papildomų D.K.M. užklausų kiekį.

Ilgalaikės atminties atnaujinimas remiasi jau aptarta dviejų dalių užklausos bei šablonų struktūra, tačiau turi du skirtingus veikimo atvejus, kuriems taikomi skirtingi užklausų šablonai. Pirmuoju atveju, naudojamas šablonas 4, kai ilgalaikė atmintis dar nėra sukurta, sistemos įvestyje modeliui priskiriamas atminties santraukų sudarytojo vaidmuo ir nurodoma suformuoti pradinę santrauką iš agento perspektyvos.

```
You are a memory summarizer for {agent_name}.
Your task is to create a concise summary of a conversation
from {agent_name}'s perspective.

Focus on:
- Key points and arguments made by participants
- Important reactions or positions taken
- Any significant agreements or disagreements
- Information that would be valuable to remember later

Important reminders:
- No preambles or introductory phrases
- Use first-person ("I") statements
- Output must be a single concise paragraph
- Length: ~35 sentences

Output format:
A single paragraph written in the first person as {agent_name}.
Do not include any introductory or explanatory text.
Start directly with the summary content.
```

Įvesties šablonas 4: Sistemos įvesties šablonas agento ilgalaikės atminties viršūnėje sukūrimo atveju

Antruoju atveju, kai ilgalaikėje atmintyje jau egzistuoja ankstesnis įrašas, naudojamas šablonas 5, sistemos įvestyje apibrėžiama atnaujinimo užduotis: integruoti naują diskusijos informaciją į esamą

ilgalaikės atminties santrauką, išlaikant tik aktualų ankstesnį kontekstą ir, prireikus, pakoreguoti agento įžvalgas įvykusioje diskusijoje.

```
You are a memory summarizer for {agent_name}.
Your task is to update an existing conversation summary
with new information.

Guidelines:
- Integrate new developments into the existing summary
- Preserve important earlier context that remains relevant
- Update or revise points if positions have changed
- Keep the summary concise but comprehensive -(46 sentences)

Important reminders:
- Integrate new information smoothly
- Retain earlier details only if still relevant
- No preambles or update notes
- Use first-person ("I") statements
- Output is a single concise paragraph

Output format:
A single paragraph written in the first person as {agent_name},-
46 sentences in length. Do not include any introductory or
explanatory text. Start directly with the summary content.
```

Įvesties šablonas 5: Sistemos įvesties šablonas agento ilgalaikės atminties viršūnėje atnaujinimo atveju

Vartotojo įvestyje pateikiama apibendrinimui reikalinga informacija, t.y. trumpalaikėje atmintyje sukauptų diskusijos žinučių ištrauka. Priklausomai nuo to, ar agentas jau turi ilgalaikės atminties įrašą, kaip ir sistemos įvestyje, naudojami du skirtingi įvesties šablonai: šablonas 6, skirtas pradinės santraukos sudarymui nuo nulio, o šablonas 7 – esamos santraukos atnaujinimui.

```
Summarize the following conversation for {agent_name}'s
long-term memory.

Conversation:
{short_memory_list}

Create a concise summary that captures the key points
and overall context.
```

Įvesties šablonas 6: Vartotojo įvesties šablonas agento ilgalaikės atminties viršūnėje sukūrimo atveju

```
Update {agent_name}'s memory summary with the new conversation.

EXISTING SUMMARY:
{existing_summary}

NEW CONVERSATION:
{short_memory_list}

Provide an updated summary that integrates the new information
while preserving relevant earlier context.
```

Įvesties šablonas 7: Vartotojo įvesties šablonas agento ilgalaikės atminties viršūnėje atnaujinimo atveju, antrajame etape

Nors šiame darbe įgyvendinta ilgalaikė atmintis nėra skirta pilnai atkartoti žmogaus atminties mechanizmus, ji dalinai atliepia šaltinyje [WWJ+25] teikiamą rekomendaciją išskaidyti sudėtingus protavimo procesus į atskirus modulius ar procesus.

4.4. Balsavimo funkcionalumas

Analizuojant darbe [POC+23] aprašytą visuomenės simuliacijos sistemos etapą, kuriame, pasitelkiant sistemos ir vartotojo įvestį, buvo realizuotas agentų interviu funkcionalumas, pastebėta, jog šis metodas leidžia gauti atsakymus iš agentų perspektyvos. Remiantis šiuo bei kitų aptartų šaltinių taikomais panašiais metodais, šiame darbe nuspręsta įgyvendinti agentų balsavimo funkcionalumą, iš dalies atliepiant aptartą simuliacijos sistemų vertinimo iššūkį. Šio funkcionalumo išvestis yra naudojama vėlesniuose skyriuose aprašomame vertinimo modulyje.

Balsavimo funkcionalumas buvo įgyvendintas kaip atskira grafo viršūnė (*vote*), į kurią buvo pereinama pasibaigus konfigūracijoje nustatytam diskusijos žingsnių skaičiui: pasiekus nustatytą žingsnių skaičių ar diskusijai pasibaigus, sistemos koordinavimo viršūnė (*supervisor*) inicijavo perėjimą į balsavimo etapą, o jo metu kiekvienas agentas buvo „iškviečiamas“ vieną kartą tam, kad pateiktų savo pasirinktą atsakymą iš galimų atsakymų sąrašo į užduotą klausimą, bei pateiktų argumentaciją. Siekiant, jog balsavimas remtųsi ne tik paskutinėmis žinutėmis, agento balsavimo vartotojo įvestyje metu pateikiama tiek trumpalaikė atmintis, tiek ir ilgalaikės atminties santrauka. Tokiu būdu siekiant suteikti agentui informaciją apie visą diskusiją, bet tik iš jo perspektyvos.

Balsavimo užklausa kaip ir kitose viršūnėse suformuojama iš dviejų dalių: sistemos įvestyje agentui primenamas jo identitetas (rolė ir savybės) bei pateikiamos balsavimo gairės, šią įvestį atitinka šablonas 8. Agentui taip pat nurodoma grąžinti struktūrizuotą rezultatą, kuriame nurodomas formatas, kaip pateikti atsakymą bei argumentaciją. Vartotojo įvestyje, kurią atitinka šablonas 9 pateikiamas balsavimo klausimas, galimų atsakymų variantai bei trumpalaikė ir ilgalaikė atmintys. Gautos balsų reikšmės kaupiamos grafo būsenos egzemplioriuje bei diskusijai pasibaigus –

išsaugomos atskirame duomenų rinkinyje, taip sudarant galimybę palyginti skirtingų simuliacijos konfigūracijų poveikį agentų galutinėms pozicijoms bei išanalizuoti diskusijos ir balsavimo sąryšį.

```
You are {agent_name}.
Your role: {agent_role_description}.

Traits:
{trait_key}: {trait_value}
{trait_key}: {trait_value}

VOTING TASK:

A group discussion has already taken place.
Your task is to cast a vote based on the discussion.

Guidelines:
- Review the aforementioned discussion carefully.
- Consider your character's values, traits, and perspective.
- Make a decision that is consistent with your established role.
- Justify your choice briefly and clearly.

Output format:
VOTE: [your choice]
REASON: [brief justification]

Reminder:
Your vote should reflect your character's internal reasoning
rather than an objective or neutral stance.
```

Įvesties šablonas 8: Sistemos įvesties šablonas agento balsavimo viršūnėje

```
Question:
{voting_question}

Available options:
- {option_1}
- {option_2}
- {option_n}

Long-term memory:
{long_memory_section}

Recent conversation summary (most recent messages):
- [{agent_name}]: {message_content}
- [{agent_name}]: {message_content}
- [...]

Instruction:
Based on the aforementioned information and your established
character perspective, cast your vote.
```

Įvesties šablonas 9: Vartotojo įvesties šablonas agento balsavimo viršūnėje

4.5. Įvestis

Siekiant išlaikyti sistemos lankstumą bei kuo didesnį rezultatų atkartojamumą, buvo sukurti konfigūracijos duomenų rinkiniai, leidžiantys nustatyti naudojamą D.K.M. ar kelis iš jų ateityje, bei jų užklausos kūrimo parametrus (angl. inference hyperparameters) ir diskusijos temą. Taip pat buvo leidžiama nustatyti kiekvieno etapo trukmę, pakeičiant žingsnių skaičių bei jau aptartą trumpalaikės atminties dydį, nustatant joje esančių žinučių limitą ir ilgalaikės atminties atsinaujinimo intervalą.

4.6. Išvestis

Šios sistemos išvestis buvo formuojama iš agentų kalbėjimo viršūnės rezultato, kuris eilės tvarka buvo talpinamas viename duomenų rinkinyje, taip sudarant galimybę įžvelgti vykusią diskusiją. Sistemos vykdymo metu, informacija apie diskusiją, įskaitant agentų žinutes, bei ilgalaikės atminties santraukas buvo kaupiama grafo būsenos žodyno duomenų klasės egzemplioriuje. Pavyzdinis sistemos diskusijos fragmentas pavaizduotas 5 pav.

```
[Sarah]: Maya, I see your point that AI can generate new roles-especially in
data science, ethics oversight, and maintenance of autonomous systems.<...>
[Simon]: Sarah, I hear you on the new roles and the urban-rural gap, but
from where we're sitting, the biggest risk is that too many built-in fairness
checks will delay deployment. <...>
[Bob]: Sarah, I agree that the urban-rural gap is a real risk. One way to keep
it in check is to collect fine-grained labor-market data-who's getting the new
roles, where, and with what skill sets-and feed that into adaptive training
programs that can roll out on demand in underserved regions.<...>
```

5 Sistemos išvestis (naudojantis „Mistral 7B“): *pirmo etapo diskusijos fragmentas*

Taip pat, atskirai buvo išsaugomas balsavimo viršūnės rezultatas, kurio pavyzdį galima matyti 6 pav.

```
[Bob]: VOTE: Agree REASON: Given my focus on long-term potential and the
significant risks associated with deploying powerful AI without robust ethical
guidelines <...>
[Sarah]: VOTE: Disagree REASON: While I acknowledge the potential for rapid
advancement, the current prioritization of "building something and figuring
it out later" demonstrates a profound disregard for accountability and the
potential for significant harm <...>
[Simon]: VOTE: Agree REASON: I'm prioritizing rapid development and
competitive advantage, believing that ethical considerations and
accountability are secondary concerns that can be addressed later. <...>
```

6 Sistemos išvestis (naudojantis „gemma3–4b“): *balsavimo fragmentas, rodantis išsiskiriančias nuomones tarp agentų*

5. Sistemos išplėtimas

Aprašyta bazinė sistema turėjo keletą apribojimų, kuriuos reikėjo pašalinti, norint pasiekti išsikeltus tikslus. Svarbiausias iš jų – personų kūrimo procesas: bazinėje versijoje kiekvienas agentas turėjo rankiniu būdu apibrėžtą vardą, rolę bei charakterio bruožų rinkinį, o tai reiškė, jog diskusijoje dalyvaujančios personos buvo tiesiogiai priklausomos nuo vartotojo žinių. Toks sprendimas neatitiko išsikeltų tikslų bei didino rezultatų šališkumą sistemos vartotojo atžvilgiu.

Siekiant šią problemą spręsti, buvo sukurtas RAG grįstas personų kūrimo modulis, kurio pagalba buvo kuriamos tema atitinkančių, suinteresuotųjų šalių personos, remiantis žiniatinklio paieškos rezultatais. Papildomai, siekiant tyrimui suteikti lyginimui skirtus duomenis, buvo sukurtas bazinis personų kūrimo funkcionalumas – kuriantis tokios pat struktūros personas, naudojant tą patį D.K.M. ir jam teikiamą įvestį, tačiau be žiniatinklio paieškos, t.y. remiantis tik modelio svoriuose užkoduota informacija.

5.1. Sistemos architektūros pakeitimai

Išplėstinė sistemos versija išlaikė bazinę sistemos grafo struktūrą. Pagrindinis skirtumas buvo tai, jog diskusijoje veikiančios personos buvo inicializuojamos ne iš statinio duomenų rinkinio, bet perduodamos iš minėto RAG ar bazinio personų kūrimo modulio.

Siekiant atliepti išsikeltus tikslus, bazinėje versijoje naudotas laisvos formos charakterio bruožų rinkinys (`traits`) buvo pakeistas argumentų rinkiniu (`keypoints`) – personai būdingais įsitikinimais ar pozicijomis temos atžvilgiu. Personos vardas ir rolės aprašymas (`role_desc`) buvo išlaikyti, tačiau sukuriami personų kūrimo modulio pagalba, o ne rankiniu būdu. Sistemos išvestyje taip pat buvo išsaugomi papildomi, su personomis susiję elementai – priklausomybė (`affiliation`), jos neapdorotas aprašas (`background`) ir pozicija (`stance`) – jie buvo naudojami personos formavimo procese, bet tiesiogiai diskusijoje nebuvo naudojami.

Šie laukai aptariami vėliau, o pavyzdinę personos struktūrą, kuri buvo naudojama diskusijoje, galima matyti sistemos išvestyje 7.

```
name: Tomas
role_desc: I am a representative of the Lithuanian Government, which is
responsible for implementing national policies and ensuring the welfare of
its citizens. I support the proposed amendments to the LRT Law because they
will enhance the governance of our public broadcaster, ensuring it operates
with greater accountability and transparency.

keypoints:
The proposed amendments aim to create a new governing board and expand the LRT
Council to include more diverse representation.
The reforms will allow for a more accountable and transparent governance
structure for the public broadcaster.
Defining the public broadcaster's mission in legislation emphasizes key values
such as impartiality, accountability, and freedom of expression<...>
```

7 Sistemos išvestis (RAG personų kūrimo modulis) *sugeneruotos personos pavyzdys*

5.2. Programinė įranga

Kuriant RAG grįstą personų kūrimo modulį, sistemoje naudotos programinės įrangos pasirinkimai buvo išsaugoti – *„LangGraph“* biblioteka išliko kaip pamatinis agentų koordinavimo sprendimas, o *„Ollama“* kaip lokalių modelių panaudojimo sprendimas. Šalia jų buvo įtraukti du nauji programinės įrangos sprendimai, reikalingi personų kūrimo moduliui: žiniatinklio paieškos įrankis bei debesijos D.K.M. prieigos sąsaja.

5.2.1. Žiniatinklio paieška – *„Tavily“*

Šio modulio žiniatinklio paieškos žingsniui, kuris yra aptariamas vėliau, buvo pasirinkta *„Tavily“* paieškos sąsaja [Tav]. Tai sąsaja, sukurta D.K.M. agentų sistemoms ir orientuota į semantika grįstos paieškos rezultatų grąžinimą. Šis sprendimas buvo priimtas siekiant išlaikyti sistemos dinamiškumą bei sutaupyti laiko, kuris turėtų būti skiriamas dokumentų paieškai, valymui bei indeksavimui, jei būtų kuriama „klasikinė“ RAG sistema.

Tokio pobūdžio sąsajų tiekėjų yra keletas, bet *„Tavily“* buvo pasirinkta atsižvelgiant į jų palyginimus šaltinyje [Fir25]. Vertinant šiuos palyginimus, svarbiausiu pasirinkimo argumentu tapo tai, jog *„Tavily“* grąžina paruoštą, semantiškai surikiuotą turinį vienu sąsajos iškvietimu, kuomet kiti tiekėjai grąžina mažiau apdorotus duomenis. Taip pat svarbu pabrėžti, jog *„Tavily“* teikia lengvatas sąsajos naudojimo kreditų pavidalu visiems studentams, šiame darbe šia lengvata buvo pasinaudota.

5.2.2. Debesijos D.K.M. prieiga – *„OpenRouter“*

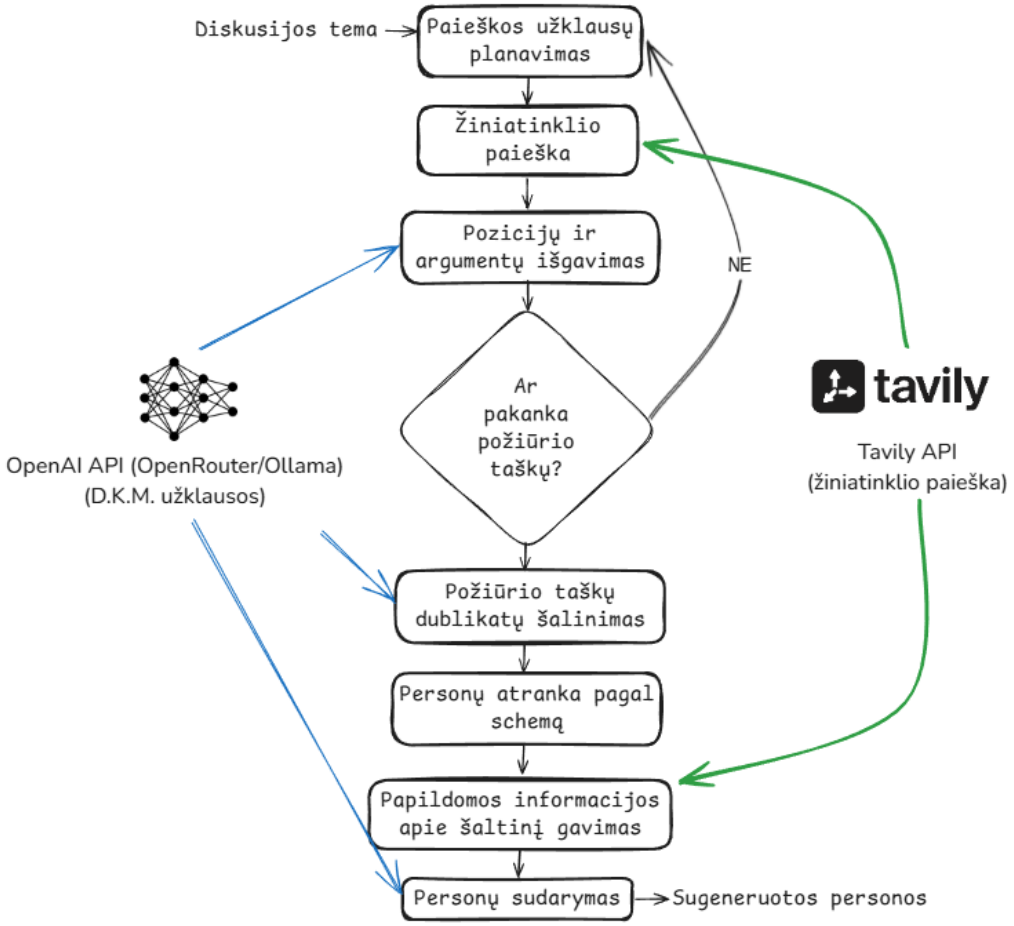
Bazinėje sistemoje visi D.K.M. buvo naudojami lokalioje aplinkoje per *„Ollama“* variklį, kas apribojo galimų modelių pasirinkimą. Siekiant išplėsti sistemos panaudojimo galimybes už lokalaus

vykdymo ribų bei suteikti prieigą prie didesnių ar komercinių modelių, šiame darbe buvo integruota *„OpenRouter“* [Ope] platformos sąsaja.

„OpenRouter“ suteikia suvienodintą prieigos sąsają, leidžiančią per vieną sąsajos tašką (angl. endpoint) pasiekti daug skirtingų tiekėjų modelių – tokių kaip *„OpenAI“*, *„Anthropic“*, *„Google“* ir kitų. Tai išsprendžia problemą, kur tiesioginių modelių tiekėjų sąsajos yra skirtingos, ir keičiant modelį tenka keisti ir su sąsaja susijusį kodą.

5.3. RAG personų kūrimo modulio įgyvendinimas

RAG personų kūrimo modulis veikia kaip atskiras, prieš diskusijos grafą vykdomas procesas. Jo pagrindine įvestimi yra laikoma diskusijos tema, o išvestimi sukurtų personų sąrašas, kuris toliau yra naudojamas paruošiant pradinę diskusijos grafo būseną. Šalia temos yra pateikiami ir kiti konfigūracijos duomenys, įskaitant ir norimų personų schemą – jie yra aptariami vėlesniuose skyriuose. Modulio veikimas susideda iš septynių nuoseklių žingsnių, kurių diagrama pavaizduota 8 pav.



8 pav. *RAG personų kūrimo modulio diagrama*

Pirmieji trys žingsniai – paieškos užklausų planavimas, žiniatinklio paieška bei pozicijų ir argumentų išgavimas sudaro ciklą. Šio ciklo tikslas yra surinkti pakankamą kiekį skirtingų požiūrio taškų apie nustatytą temą. Ciklas kartojamas tol, kol surinktų požiūrio taškų skaičius pasiekia konfigūracijoje nustatytą slenkstį (arba yra pasiekiamas maksimalus iteracijų skaičius). Surinkus pakankamą

požiūrio taškų kiekį, vykdomi likę žingsniai: dublikatų šalinimas, pozicijų atranka pagal schemą, papildomos informacijos apie šaltinius gavimas bei galutinis personų sudarymas. Kiekvienas iš šių žingsnių toliau aptariamas atskirai.

5.3.1. Paieškos užklausų planavimas

Pirmajame žingsnyje D.K.M. pagal pateiktą diskusijos temą sukuria žiniatinklio paieškos užklausų sąrašą, kurio ilgis yra nustatomas konfigūracijoje. Modelio įvestyje nurodoma užduotis – sukurti neutralias užklausas, vengiant pozicijų nusakančių žodžių – taip siekiant gauti kuo „platesnius“ ir mažiau šališkus paieškos rezultatus.

Šis žingsnis yra minėto ciklo dalis, ir po pirmųjų užklausų sukūrimo ankstesnių iteracijų užklausos yra perduodamos modelio įvestyje, siekiant išvengti pasikartojimų. Pavyzdiniai šio žingsnio rezultatai pateikiami išvestyje 9.

```
1. "2024 Lithuanian Civil Union Bill details"
2. "Lithuanian Seimas Civil Union Bill discussion"
3. "legal equality in Lithuania 2024"
4. "stakeholders in Lithuanian Civil Union Bill"
5. "Lithuanian Civil Union Bill adoption process"
```

9 Sistemos išvestis (RAG personų kūrimo modulis): *paieškos užklausų planavimo žingsnio pavyzdinė išvestis*

5.3.2. Žiniatinklio paieška

Užklausos iš praeito žingsnio kaip įvestis perduodamos *„Tavily“* paieškos sąsajai. Tuomet kiekvienai užklausai grąžinamas rezultatų kiekis, kuris neviršija konfigūracijoje nustatytos ribos, taip siekiant valdyti modeliui pateikiamo konteksto dydį. Konfigūracijoje taip pat yra nustatomas domenų sąrašas, kuriam vykdymo metu, paieškos įrankis teikia prioritetą.

Kiekvienas rezultatas grąžinamas kaip turinio fragmentas su šaltinio nuoroda bei užklausa, kuri buvo pateikta sąsajai – taip sudarant galimybę sekti pirminius duomenų šaltinius. Šie rezultatai vėliau naudojami kaip įvestis požiūrio taškų išgavimo žingsniui. Pavyzdiniai šio žingsnio rezultatai pateikiami išvestyje 10.

```
query: "2025 amendments Lithuania LRT Law"
content: Board and Council reforms: The proposals would create a new governing
board while<...>
url: https://www.lrt.lt/en/news-in-english/19/2850192/what-changes-are-
proposed-to-lrt-law<...>
```

10 Sistemos išvestis (RAG personų kūrimo modulis): *žiniatinklio paieškos žingsnio pavyzdinės išvesties fragmentas*

5.3.3. Pozicijų ir argumentų išgavimas

Trečiajame žingsnyje paieškos rezultatai suskaidomi ir konfigūracijoje nustatytomis dalimis pateikiami skirtingose D.K.M. užklausose. Sistemos įvestyje modeliui yra nurodoma kiekviename paieškos rezultatų fragmente identifikuoti suinteresuotas šalis ir užfiksuoti: jų pavadinimus, argumentus bei pozicijas temos atžvilgiu. Tokiu būdu išgaunama pirminė personos informacija, kurią modelis turi pateikti struktūrizuotai šiuo *JSON* formatu:

- `source_name` – suinteresuotos šalies pavadinimas.
- `source_type` – suinteresuotos šalies kategorija (`government`, `ngo`, `business`, `academic`, `media` arba `other`).
- `stance` – pozicija temos atžvilgiu (už, prieš arba neutrali),
- `key_arguments` – 2–4 konkretūs argumentai ar interesai, būdingi šiai suinteresuotai šaliai.
- `sources` – šaltinių nuorodų sąrašas, iš kurių šie argumentai buvo išgauti.

Pavyzdiniai šio žingsnio rezultatai pateikiami išvestyje 11.

```
source_name: Lithuanian Government
source_type: government
stance: support
key_arguments:
- The proposed amendments aim to create a new governing board and expand the
LRT Council to include more diverse representation.
- The reforms will allow for a more accountable governance structure by
requiring a two-thirds vote for the dismissal of the director general.
- Defining the public broadcaster's mission in legislation emphasizes key
values such as impartiality, accountability, and freedom of expression.
sources:
- https://www.lrt.lt/en/news-in-english/<...>
```

11 Sistemos išvestis (RAG personų kūrimo modulis): *požiūrio taško išgavimo žingsnio išvesties fragmentas*

5.3.4. Požiūrio taškų dublikatų šalinimas

Įgyvendinus minėtus žingsnius buvo pastebėta, jog neretai yra sudaromos pasikartojančios personos, kuriose:

- Pavadinimai įvardija tapačią šalį, bet skiriasi dėl skirtingo duomenų formatavimo (sutrumpinimų naudojimo, mažųjų ir didžiųjų raidžių maišymo ir panašių pokyčių)
- Skiriasi pozicija temos atžvilgiu nors šalis sutampa.

- Skiriasi arba pasikartoja argumentai.

Šiai problemai išspręsti buvo įgyvendintas papildomas žingsnis, kuris dvejomis fazėmis atliko dublikatų šalinimą. Pirmojoje fazėje buvo taikomas taisyklėmis grįstas dublikatų šalinimo metodas: aktoriaus pavadinimas yra normalizuojamas (mažosios raidės, be skyrybos ženklų) ir visi kiti personą apibrėžiantys elementai su sutampančiais normalizuotais pavadinimais yra sujungiami: argumentai, šaltinių nuorodos, o pozicijų konfliktų atveju požiūrio taško pozicija nustatoma kaip maišyta (angl. mixed). Antrojoje fazėje normalizuotų personų sąrašas perduodamas D.K.M. kaip vartotojo įvestis. Sistemos įvestyje modeliui nurodoma sujungti įrašus, nurodančius tą pačią suinteresuotą šalį skirtingomis pavadinimo formomis – taip identifikuojami ir pašalinami semantiniai dublikatai, kurių taisyklėmis grįstas, tekstinis palyginimas nesuranda.

5.3.5. Personų atranka pagal schemą

Atsižvelgiant į šaltinyje [TDR+24] tirtus personos pozicijų duomenis buvo svarbu sistemoje sudaryti sąlygas pasirinkti norimą suinteresuotų šalių sąrašą pagal konfigūracijoje pateikiamą pozicijų schemą, kurios pavyzdį galima matyti konfigūracijos pavyzdyje 12.

```
PERSONA_STANCE_SCHEMA = {
"support": 2,
"oppose": 2
}
```

12 Konfigūracijos pavyzdys: *pozicijų atrankos schemos konfigūracijos pavyzdys*

Remiantis šia schema buvo atrenkamas nustatytas personų ir jų pozicijų kiekis. Šios sistemos įgyvendinimo ir tyrimo atlikimo metu personų sąrašas visada būdavo didesnis nei schema reikalavo, todėl kandidatai pasirinkimui turėjo būti rikiuojami – teikiant prioritetą personoms su daugiausiai argumentų. Buvo daroma prielaida, jog jie atrinktuose šaltiniuose buvo daugiausiai minimi, todėl turėjo didžiausią įtaką duotajai temai.

5.3.6. Papildomos informacijos apie šaltinį gavimas

Šiame žingsnyje pritaikomas šaltinio [TDR+24] metodas – kurti personas su praeities istorija – papildant jį šaltinio [GHT24] įžvalga, jog detaliau aprašytos personos pasiekia geresnius rezultatus.

To pasekoje kiekvienai pasirinktai personai buvo vykdoma papildoma *„Tavily“* paieška, kurios tikslas buvo išgauti papildomą kontekstą personos aprašymui. Paieškos užklausa buvo sudaroma iš aktoriaus pavadinimo, jo kategorijos, žodžio „Lithuania“ bei diskusijos temos. Papildomas žodis Lietuva buvo pridėtas pastebėjus, jog personos pavadinimas retkarčiais yra bendrinis ir paieška gražina ne Lietuvos kontekste esančius šaltinius, o tyrime buvo siekiama tirti būtent Lietuvos kontekstą. Papildomai svarbu paminėti, jog paieškos įrankiui buvo pateikiamas enciklopedinių šaltinių domenų sąrašas.

Galiausiai, gauti rezultatai buvo apribojami iki 800 simbolių – konteksto dydžiui valdyti. Tuomet jie buvo pridedami prie personos objekto kaip `enrichment_raw` laukas ir perduodami sekančiam žingsniui.

5.3.7. Personų sudarymas

Paskutiniame žingsnyje kiekvienam personos objektui buvo vykdoma atskira D.K.M. užklausa. Jos tikslas buvo pasinaudoti iki šiol sukaupta informacija ir sukurti galutinę modulio išvestį – personos objektus.

Sistemos įvestyje modeliui buvo pateikiamos instrukcijos remtis vartotojo įvestyje pateikta informacija ir sukurti šiuos personos laukus:

- `role_desc` – 1-2 sakinių pirmo asmens personos aprašymas, kuriame turi atsispindėti personos atstovaujama suinteresuota šalis ir jos pozicija temos atžvilgiu;
- `background` – 1-2 sakinių kontekstas apie suinteresuotą šalį, grįstas papildoma informacija iš praeito žingsnio ir nekartojantis `role_desc` (sistemos kūrimo eigoje buvo nuspręsta šio lauko nenaudoti diskusijoje dėl prastos kokybės).

Vartotojo įvestyje modeliui buvo pateikiama ši informacija: diskusijos tema, suinteresuotos šalies pavadinimas, jos kategorija bei pozicija temos atžvilgiu, argumentų rinkinys bei papildomas kontekstas iš praeito žingsnio. Personos vardas diskusijai buvo parenkamas iš anksto sudaryto lietuviškų vardų sąrašo – taip siekiant pritaikyti bazinės diskusijų sistemos metodiką, darant prielaidą, jog naudojant suinteresuotų šalių pavadinimus reiktų keisti ir įvesties nurodymus. Pavyzdiniai šio žingsnio bei viso modulio rezultatai pateikiami išvestyje 13.

name: Marta
affiliation: Nemunas Dawn
stance: support

role_desc: I am a representative of Nemunas Dawn, a political party focused on promoting populist and nationalist values in Lithuania. I support the proposed amendments to the LRT Law because enhancing accountability within public broadcasting is crucial for ensuring it fulfills its mission to the public.

background: Nemunas Dawn, founded in November 2023, gained representation in the Seimas in June 2024 after three MPs joined from other parties. The party has quickly established itself in the political landscape, particularly in the southern regions of Samogitia and Lithuania Minor.

keypoints:
- The proposed amendments aim to enhance accountability and governance within the LRT by allowing for easier dismissal of the director general.
- Lowering the threshold for removing the LRT director general is seen as a necessary step to ensure the broadcaster meets its public mission.
- The party has suggested that the dismissal vote could be made a secret ballot to protect council members.

sources:
- https://www.lrt.lt/en/news-in-english/19/2850192/<...>
- https://www.lrt.lt/en/news-in-english/19/2759399/<...>

13 Sistemos išvestis (RAG personų kūrimo modulis): *sukurtos personos pavyzdys*

Kiti personos laukai – `affiliation`, `keypoints`, `stance` ir `sources` – buvo perkeliami be papildomų D.K.M. transformacijų. Galiausiai svarbu dar kartą pabrėžti, jog `stance`, `affiliation` bei `sources` laukai nebuvo naudojami diskusijos metu, tačiau buvo išsaugomi išvesties duomenų rinkiniuose siekiant stebėti sistemos veikimą ir palengvinti rezultatų analizę bei atsekamumą.

5.4. Bazinis personų kūrimas

Siekiant įvertinti RAG grįsto personų kūrimo modulio poveikį diskusijų sistemos veikimui, reikėjo sukurti palyginimui skirtus duomenis bei metodą, kuris generuotų tokios pačios struktūros personas, tačiau be žiniatinklio.

Bazinis metodas naudoja vieną D.K.M. užklausą sukurti visoms personoms. Modelio įvestyse yra pateikiama diskusijos tema ir pageidaujama personų pozicijų schema – tokia pati, kokia naudojama ir RAG metode. Sistemos įvestyje modeliui nurodoma sukurti suinteresuotų šalių personas, atitinkančias nurodytas pozicijas ir kiekvienos iš jų kiekį.

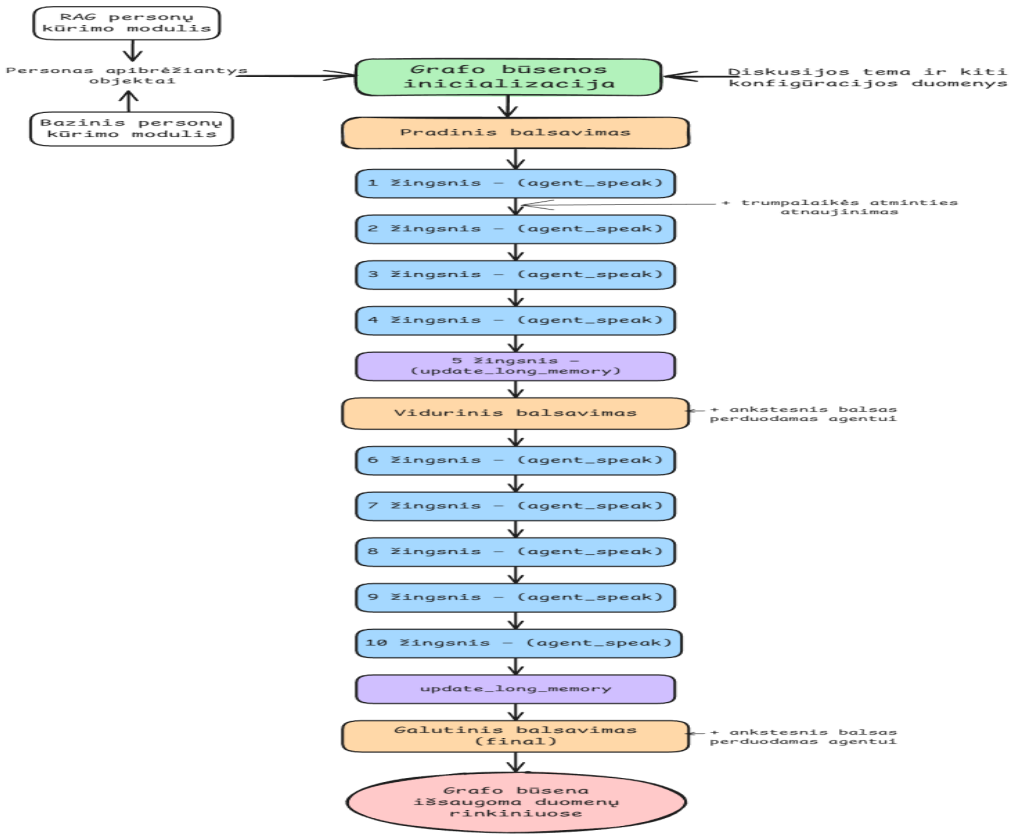
Modeliui taip pat nurodoma grąžinti rezultatą struktūrizuotu *JSON* formatu ir užtikrinti, jog

kiekviena persona turėtų tokius pačius laukus kaip RAG modulio išvestis: `affiliation`, `role_desc`, `keypoints`, `background`, `stance`. Kaip ir RAG atveju, personų vardai parenkami iš to paties, iš anksto sudaryto lietuviškų vardų sąrašo.

5.5. Balsavimo funkcionalumo pakeitimai

Bazinėje sistemoje balsavimas buvo vykdomas vieną kartą – diskusijai pasibaigus. Išplėstinėje versijoje balsavimo funkcionalumas buvo praplėstas siekiant suteikti galimybę stebėti pozicijų kaitą diskusijos eigoje: balsavimas vykdomas tris kartus – prieš diskusiją, jos viduryje ir pabaigoje. Šis sprendimas buvo priimtas siekiant suteikti tyrimo vertinimo moduliui duomenis, leidžiančius nustatyti, ar ir kaip agentų pozicijos kito diskusijos metu, kaip buvo daroma šaltinyje [TDR+24].

Papildomai buvo įgyvendintas mechanizmas, užtikrinantis, jog vidurinio ir galutinio balsavimo metu ilgalaikė atmintis yra atnaujinta. Kadangi įprastas ilgalaikės atminties atnaujinimas vyksta pagal konfigūruojamą intervalą, galėjo susidaryti situacija, kuomet pereinant į balsavimo etapą ilgalaikė atmintis neatspindėjo naujausių diskusijos įvykių ir suteikė „pasenusį“ kontekstą balsavimo viršūnei. To pasekoje, koordinavimo viršūnės logika buvo papildyta nauju funkcionalumu, kuris užtikrino, jog prieš vidurinį ir galutinį balsavimą yra tikrinama, ar ilgalaikė atmintis nebuvo atnaujinta einamuoju diskusijos žingsniu – jei ne, vykdomas papildomas atnaujinimas, ir tik po jo pereinama į balsavimo viršūnę. Pavyzdinę išplėstinės sistemos vykdymo eigą, įskaitant visus tris balsavimo etapus, galima matyti 14 pav.



14 pav. *Išplėstinės diskusijų sistemos vykdymo sekos iliustracija (10 žingsnių pavyzdys)*

5.6. Vertinimo modulis

Vertinimo modulis buvo sukurtas siekiant įvertinti, ar RAG grįstas personų kūrimo metodas daro išmatuojamą poveikį diskusijų sistemos veikimui, lyginant su baziniu metodu. Taip pat buvo siekiama įvertinti ar skirtingais metodais kuriamos personos turi išmatuojamą skirtumą – tai buvo pasirinkta daryti apskaičiuojant jų panašumą. Bazinėje sistemoje buvo taikomas D.K.M. teisėjo (angl. *LLM-as-a-Judge*) vertinimo metodas, kuris leido gauti kokybinį diskusijų vertinimą, bet šio darbo tyrimo tikslams pasiekti buvo reikalingi kiekybiniai, deterministiški duomenys. Buvo nuspręsta, jog D.K.M. teisėjo metodas be realių žmonių – vertintojų, ar kitų išorinių, palyginimui skirtų duomenų, yra nepakankamas siekiant daryti išvadas apie dviejų metodų palyginimą.

To pasekoje vertinimo modulis buvo suprojektuotas iš naujo ir išskaidytas į dvi dalis. Pirmoji dalis buvo skirta personų įvairovės vertinimui – jos pagalba buvo siekiama išmatuoti, kiek sukurtos personos yra įvairios tarpusavyje bei tarp skirtingų sistemos iteracijų. Antroji dalis buvo skirta išmatuoti agentų pozicijų pasiskirstymui, jų atitikimui priskirtoms pozicijoms (personas apibrėžiančiuose objektuose) bei pozicijų kaitai diskusijos eigoje.

5.6.1. Personų vertinimas

Personų vertinimo modulis buvo skirtas matuoti dviejų skirtingų personų kūrimo metodų – RAG ir bazinio, sukurtų personų įvairovę dvejais rodikliais:

- personų įvairovę vienos iteracijos ribose; ir
- personų įvairovė keliose iteracijose;

Vertinimui buvo naudojamas konfigūracijoje nustatytas sakinių įterpinių modelis. Jo pagalba kiekvienos personos priklausomybės (`affiliation`) ir argumentų (`keypoints`) laukai buvo paverčiami atskirais įterpiniais, kur viena priklausomybės reikšmė arba vienas argumentas atitiko vieną įterpinį. Semantinis panašumas tarp dviejų tokių įterpinių rinkinių buvo skaičiuojamas naudojant $N \times M$ kosinuso panašumo matricą, kurioje kiekvienas pirmojo rinkinio įterpinys buvo palyginamas su kiekvienu antrojo rinkinio įterpiniu.

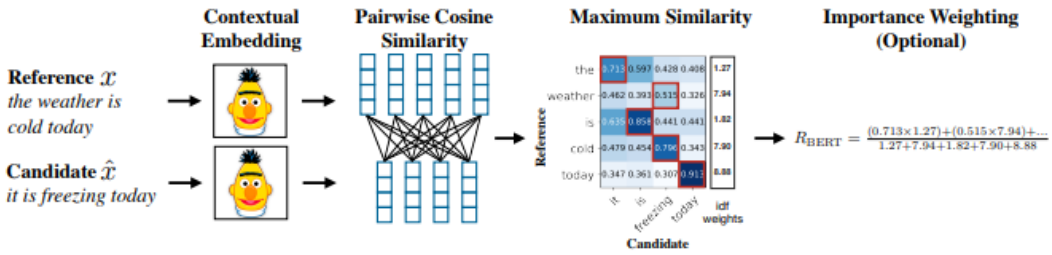
Personų įvairovė iteracijos ribose

Pirmasis rodiklis matavo, kiek toje pačioje iteracijoje sukurtos personos semantiškai skiriasi viena nuo kitos. Kiekvienai personų porai (i, j) buvo skaičiuojami du atskiri panašumo įvertinimai.

Priklausomybių panašumas buvo gaunamas iš 1×1 kosinuso panašumo matricos, kur kiekviena persona poroje turėjo po vieną `affiliation` reikšmę – lygiavertis matavimas paprastai kosinuso panašumo operacijai.

Argumentų panašumas buvo skaičiuojamas naudojantis $K_i \times K_j$ matrica, kur K_i ir K_j atitiko personų `keypoints` argumentų įterpinius. Tuomet kiekvienam i-osios personos argumento įterpiniui

buvo surandamas semantiškai artimiausias j-osios personos argumentas (maksimali kosinuso panašumo vertė eilutėje); ir atvirkščiai (maksimali kosinuso panašumo vertė stulpelyje), o galutinė vertė apskaičiuojama kaip abiejų krypčių vidurkių vidurkis. Šis skaičiavimo principas yra įkvėptas *BERTScore* metrikos [ZKW+19], kurioje semantinis teksto panašumas vertinamas lyginant kandidato ir atskaitos teksto įterpinius, šio skaičiavimo seka matoma 15 diagramoje. Skirtingai nei originalus *BERTScore* rodiklis, šiame darbe buvo lyginami ne žetonų (angl. tokens) lygmens įterpiniai, o personų argumentų bei jų reprezentacijų rinkinių įterpiniai.



15 pav. *BERTScore skaičiavimo seka [ZKW+19]*

Galiausiai kiekvienam rodikliui buvo išsaugomos šios vertės: jo vidurkis, minimumas ir maksimumas per visas iteracijos personų poras. Žemesnė vidurkio reikšmė rodo įvairesnes personas, o aukštesnė – panašesnes.

Personų įvairovė keliose iteracijose

Antrasis rodiklis matavo semantinį panašumą keliose iteracijose. Kaip ir ankstesniame rodiklyje, kiekvienai iteracijų porai buvo skaičiuojami du panašumo įvertinimai – priklausomybių ir argumentų. Taip pat buvo naudojama maksimumo paieška ir dvigubas vidurkis.

Skirtumas pasireiškė per duomenų grupavimą: čia `affiliation` ir `keypoints` įterpiniai nebuvo lyginami kiekvienai personai atskirai, vietoj to jie buvo sugrupuojami į rinkinius ir buvo lyginami visi vienos iteracijos įterpiniai su kitos iteracijos rinkiniu. Priklausomybių atveju buvo sudaroma $A_i \times A_j$ matrica, kur A_i žymėjo visų i-osios iteracijos personų `affiliation` priklausomybių įterpinių rinkinį, o A_j – j-osios.

Analogiškai argumentų atveju buvo sudaroma $P_i \times P_j$ matrica, kur P_i ir P_j buvo atitinkamų iteracijų visų personų `keypoints` įterpiniai, sujungti į vieną rinkinį. Galiausiai kiekvienai iteracijos porai buvo išsaugoma priklausomybių ir argumentų panašumo vertė, o sesijos lygmeniu buvo skaičiuojamas jų vidurkis per visas iteracijos poras. Aukštesnė vidurkio reikšmė reiškia stabilesnį (panašesnį) modulio veikimą – skirtingi paleidimai kuria semantiškai panašias personas.

5.6.2. Balsavimo vertinimas

Balsavimo vertinimo modulis matavo agentų balsavimo elgseną diskusijos eigoje ir sudarė tris rodiklius:

- balso atitikimą priskirtai personos pozicijai;
- balso pozicijos kaitą tarp diskusijos etapų;
- balsų pasiskirstymą bei vidutinę visų agentų poziciją;

Visi trys rodikliai rėmėsi tais pačiais pradiniais duomenimis – kiekvieno agento balsais trijuose etapuose: *pradiniame* (prieš diskusiją), *viduriniame* (po pusės diskusijos žingsnių) ir *galutiniame* (po viso diskusijos ciklo) skyrėsi tik skaičiavimai. Atitikimo rodiklis lygino balso reikšmę su personos pozicija (`stance`), kaitos rodiklis balsus pavertė skaitinėmis reikšmėmis ir matavo jų skirtumus tarp etapų, pasiskirstymo rodiklis sumavo, kiek kartų buvo pasirinktas kiekvienas iš penkių galimų balsavimo variantų.

Viso sistemos kūrimo ir tyrimo metu balsavimo viršūnėje buvo pateikiamas šis klausimas:

Remiantis diskusija, kokia yra jūsų pozicija šia tema?
(angl. Based on the discussion, what is your position on the topic?)

Su šiais galimais atsakymais, sudarančiais penkiabalę Likerto tipo skalę:

- **Visiškai pritariu** (angl. *Strongly For*);
- **Pritariu** (angl. *For*);
- **Neutrali pozicija** (angl. *Neutral*);
- **Nepritariu** (angl. *Against*);
- **Visiškai nepritariu** (angl. *Strongly Against*).

Skaitiniam balsavimo elgsenos vertinimui buvo naudojamas vienodas balsų reikšmių vertimas:

Visiškai pritariu $\rightarrow +2$, Pritariu $\rightarrow +1$, Neutrali pozicija $\rightarrow 0$, Nepritariu $\rightarrow -1$, Visiškai nepritariu $\rightarrow -2$.

Šie rodikliai pasirinkti siekiant suteikti skaitines vertes balsavimo bei jo pokyčio pasiskirstymui bei įvertinti ar agentai seka priskirtas pozicijas ir kaip jos kinta.

Balso atitikimas priskirtai pozicijai

Pirmasis rodiklis matavo, kiek agentų balsavo pagal jiems personoje priskirtą poziciją (`stance`). Kiekvienai pozicijai apibrėžiant, kurie iš penkių galimų balsavimo variantų laikomi atitinkamais pozicijai:

- palaikantis $\rightarrow$ {*Pritariu*, *Visiškai pritariu*}
- prieštaraujantis $\rightarrow$ {*Nepritariu*, *Visiškai nepritariu*}
- neutralus $\rightarrow$ {*Neutrali pozicija*}

Kiekvienam diskusijos etapui buvo suskaičiuojama, kiek kiekvieno agento balsų pateko į jo poziciją atitinkančių balsų aibę (rezultatas pateikiamas procentine išraiška). Aukštesnė reikšmė rodo, jog agentai laikosi savo personos pozicijos. Žemesnė reikšmė reiškia, jog agentai balsavimo metu nukrypo nuo priskirtos pozicijos. Rodiklis skaičiuojamas atskirai kiekvienam iš trijų etapų, taip sudarant galimybę stebėti atitikimo kaitą diskusijos metu.

Balso pozicijos kaita tarp etapų

Antrasis rodiklis matavo kiekvieno agento balso pokytį pereinant iš vieno etapo į kitą. Naudojant aukščiau aprašytą balso į skaitinę reikšmę vertimą. Kiekvienam agentui a ir etapų porai (s_1, s_2) buvo skaičiuojamas skirtumas $\Delta_{a,s_1 \rightarrow s_2} = v_{a,s_2} - v_{a,s_1}$, kur $v_{a,s}$ yra agento a balso skaitinė reikšmė etape s.

Iš šių skirtumų buvo sudaromi du atskiri įvertinimai:

- vidutinis balsavimo pokytis – šis įvertinimas turi ženklą ir rodo, į kurią pusę pakito agentų grupės nuomonę: teigiama reikšmė reiškia pasikeitimą palaikymo link, neigiama – prieštaravimo link.
- vidutinis absoliutus pokytis – šis įvertinimas neturi ženklo ir rodo bendrą balsavimo kaitos intensyvumą – kiek vidutiniškai vienas agentas pakeitė savo poziciją, neatsižvelgiant į kryptį.

Abu įvertinimai skaičiuojami visoms trims skirtingų balsavimo etapų poroms – pradinis $\rightarrow$ vidurinis, vidurinis $\rightarrow$ galutinis, pradinis $\rightarrow$ galutinis.

Balsų pasiskirstymas ir vidutinė pozicija

Trečiasis rodiklis žvelgia į visus diskusijoje dalyvavusius agentus tiek bendrai, tiek atskirai. Kiekvienam etapui skaičiuojami du įvertinimai:

Pirmasis – balsų pasiskirstymas: kiek kartų etape buvo pasirinktas kiekvienas iš penkių balsavimo variantų. Šis įvertinimas leidžia matyti, ar diskusija veda link konsensuso (dominuoja vienas balsavimo variantas), poliarizacijos (dominuoja kraštutiniai variantai) ar fragmentacijos (balsai pasiskirstę tolygiai).

Antrasis – vidutinė pozicija, gaunama suskaičiavus vidurkį iš agentų balsų skaitinių reikšmių kiekviename etape. Šis įvertinimas rodo nuomonės centrą skaitinėje skalėje nuo -2 iki $+2$. Lyginant trijų etapų reikšmes matoma diskusijos trajektorija – bendra kryptis, į kurią krypdavo balsai nuo pradinio iki galutinio balsavimo etapo.

Abu įvertinimai skaičiuojami dviem lygmenimis: visos grupės – apjungiant visus etapo balsus į vieną pasiskirstymą ir vieną vidurkį, ir atskirų agentų – kiekvienam agentui sudarant jo balsų pasiskirstymą bei vidutinę poziciją per visas iteracijas. Pirmasis lygmuo atskleidžia grupės nuomonės elgseną, o antrasis – kiekvieno agento individualų polinkį ir jo stabilumą.

Leidžiant sistemą kelias iteracijas, yra skaičiuojamas kiekvieno rodiklio vidurkis – taip gaunami galutiniai dydžiai, kuriuos galima palyginti tarp RAG grįsto ir bazinio personų kūrimo metodų.

6. Tyrimas

Tyrimo metu visu pirma buvo siekiama išmatuoti, ar skirtingais metodais sukurtos personos pastebimai skiriasi, tuomet buvo siekiama ištirti RAG grįsto personų kūrimo modulio poveikį diskusijos eigai bei patikrinti, ar diskusijoje bendrai susiformuoja tokie patys dėsningumai kaip šaltinyje [TDR+24]. To pasekoje, buvo įgyvendinti du tyrimo etapai, kuriuose pasikartojantys kintamieji buvo temų bei modelių pasirinkimas, o kiti kintamieji buvo nustatyti pagal etapo poreikius.

6.1. Pasirinktos temos

Tyrimui buvo pasirinktos dvi diskusijos temos, susietos su Lietuvos kontekstu.

Pirmoji tema – *„Siūlomi 2025 metų „LRT“ įstatymo pakeitimai yra būtina „LRT“ vadovybės reforma ir turėtų būti priimti seime.“* (angl. *„The proposed 2025 amendments to Lithuania's LRT Law represent a necessary reform of public broadcaster governance and should be passed by the Seimas.“*).

Ši tema pasirinkta dėl temoje minimų įvykių laiko, daroma prielaida, jog ši tema turi mažą persidengimą su duomenimis, naudotais D.K.M. mokymuisi, nes pakeitimų svarstymas ir susijusi informacija žiniatinklyje atsirado 2025–2026 metais ir gali sudaryti skirtumus tyrimo eigoje.

Antroji tema – *„2024 metų Lietuvos partnerystės įstatymo projektas buvo būtinas žingsnis siekiant teisinės lygybės ir turėjo būti priimtas Seimo.“* (angl. *„The 2024 Lithuanian Civil Union Bill represented a necessary step toward legal equality and should have been adopted by the Seimas.“*)

Tos pačios lyties santykių legalizavimo/formalizavimo klausimai buvo keliami keliose Lietuvos seimo kadencijose, ypač aktyviai 2023–2024 metais, bei 2025 dėl konstitucinio teismo nutarimo. Keliama hipotezė, jog šis klausimas turėtų būti naudojamų modelių treniravimui skirtų duomenų rinkiniuose ir tai gali sudaryti pastebimą pokytį lyginant su ankščiau minėta tema. Galiausiai daroma prielaida, jog žiniatinklyje abiems temoms yra pakankamai šaltinių, atspindinčių tiek palaikančias, tiek priešingas pozicijas.

Temos suformuluotos panašiu principu: abiejuose yra pateikiama aiški pozicija, taip siekiant sudaryti palankias sąlygas RAG bei baziniam personų kūrimo moduliui priskirti personų pozicijas, bei tikslingai sudaryti balsavimo klausimą, kuris buvo paminėtas 5.5. skyriuje.

6.2. Naudojami modeliai

6.2.1. Didieji kalbos modeliai

Tyrime naudoti du skirtingos architektūros ir dydžio D.K.M.: *„Llama 4 Maverick“* ir *„Gemma 3 27B“*. Jie pasirinkti siekiant palyginti, ar RAG grįsto ir bazinio personų kūrimo metodų skirtumai išlieka keičiant ne tik personų kūrimo metodą, bet ir patį modelį. Šių modelių pasirinkimas nėra skirtas sudaryti pilnavertiškam visų visų D.K.M. spektro palyginimui, bet įvertinti galimą jų efektą šiam moduliui.

Papildomai abu modeliai pasirinkti todėl, kad jų mokymo duomenų žinių riba yra labai panaši – abiem atvejais šaltiniuose nurodoma 2024 m. rugpjūčio mėn. riba. Tai svarbu, nes laiko požiūriu šie modeliai patenka tarp dviejų pasirinktų temų: ankstesnės 2024 m. partnerystės įstatymo temos ir vėlesnės 2025 m. *„LRT“* įstatymo pataisų temos.

- *„Llama 4 Maverick“* [Met25]
  Parametrų skaičius: **400 milijardų (17 milijardų aktyvūs išvesties kūrimo metu)**
  Architektūra: **„Mixture-of-Experts“ (MoE)**
  Svorių tikslumą nusakantis formatas: **MXFP4 (kombinacija tarp FP4 kvantizacijos ir didesnio tikslumo skaičiavimų)**
  Išleidimo data: **2025–04–05**

- *„Gemma 3 27B“* [Goo25]
  Parametrų skaičius: **27 milijardai**
  Architektūra: **tanki (angl. dense)**
  Svorių tikslumą nusakantis formatas: **BF16**
  Išleidimo data: **2025–03**

6.2.2. Sakinių įterpinių modelis

Personų semantinio panašumo vertinimui naudotas sakinių įterpinių modelis *„all-mpnet-base-v2“* [Sen21]. Šis modelis pasirinktas todėl, kad vertinimo modulyje lyginami ne pavieniai teksto žetonai, o sakiniai. Todėl reikalingas modelis, kuris kiekvieną sakinį arba trumpą teksto fragmentą paverčia vienu semantiniu vektoriumi.

Būtent šis modelis pasirinktas kaip kompromisas tarp kokybės, prieinamumo ir skaičiavimo sąnaudų, lyginant su kitais, panašios architektūros ir paskirties modeliais.

6.3. Pirmasis etapas – personų palyginimas

Pirmajame tyrimo etape buvo siekiama palyginti RAG grįstą ir bazinį personų kūrimo metodą bei nustatyti ar sukurtos personos pastebimai skiriasi ir ar skirtumas gali būti apskaičiuotas. Analizei

naudojamas personų vertinimo modulis, aprašytas skyriuje 5.6.1., kurio pagalba yra sudaromi du rodikliai – personų įvairovę vienos iteracijos ribose ir personų įvairovė keliose iteracijose.

6.3.1. Metodologija

Pirmojo etapo tyrimui buvo pasirinkti keturi kintamieji, kiekvienas su dviem variantais: personų kūrimo metodas, naudojamas D.K.M., pozicijų schema ir diskusijos tema. To pasekoje, buvo gautos $2^4 = 16$ kombinacijos (8 kiekvienam metodui), kurių kiekviena buvo vykdoma 10 iteracijų.

Užklausų kūrimo temperatūra

Personų kūrimo etapui buvo naudojamos dvi skirtingos modelio išvesties užklausų kūrimo temperatūros:

- **RAG metodui** – temperatūra `0.1`: žema reikšmė pasirinkta siekiant, jog modelis kiek galima tiksliau atspindėtų iš žiniatinklio gautą informaciją.
- **Baziniam metodui** – temperatūra `0.7`: aukštesnė reikšmė pasirinkta siekiant kompensuoti žiniatinklio paieškos nebuvimą ir suteikti modeliui daugiau „laisvės“ kurti įvairesnes personas remiantis tik svoriuose užkoduotomis žiniomis, bet ne maksimaliai aukšta – siekiant išlaikyti įvestyse pateikiamos instrukcijos vykdymą – kurti išvestį pagal struktūrizuotą šabloną.

RAG personų kūrimo modulio konfigūracijos parametrai

RAG personų kūrimo modulyje buvo naudojami šie konfigūracijos parametrai:

- **Užklausų kiekis planavimo žingsnyje** (`RAG_QUERY_COUNT`) = `5` – Šis skaičius pasirinktas kaip kompromisas tarp užtektinai plačios pasirinktų tėmų aprėpties ir vykdymo laiko. Buvo pastebėta, jog šiose temose, daugiau skirtingų užklausų grąžina duomenis iš neaktualių šaltinių arba kartoja tuos pačius.
- **Požiūrio taškų minimalus skaičius** (`RAG_MIN_VIEWPOINTS`) = `40` – Šis skaičius pasirinktas pastebėjus, jog su `5` užklausomis vidutiniškai išgaunama nuo 15 iki 30 neapdorotų personų objektų. Su šia apatine riba buvo siekiama užtikrinti, jog RAG personų kūrimo modulyje esantis ciklas vykdytų bent dvi paieškos iteracijas siekiant jį išnaudoti, tikintis, jog didesnis duomenų skaičius finalinėms personoms sudaryti lems pastebimesnį metodų skirtumą.

Agentų personų pozicijų schemos

Tyrimui buvo pasirinktos dvi pozicijų schemos, aprašytos skyriuje 5.3.5.:

- **schema A (palaiko $\times$ 2, prieštarauja $\times$ 1)**
- **schema B (palaiko $\times$ 1, prieštarauja $\times$ 2)**

Vertinimui buvo pasirinktos būtent šios schemos siekiant įvertinti personas, kurios bus dalinai naudojamos antrajame etape ir tuo pačiu padengti daugiau skirtingos pozicijos agentų.

Schema su neutralios pozicijos agentu buvo taip pat svarstyta, tačiau jos buvo atsisakyta, nes atliekant dublikatų šalinimo žingsnį kombinacijose su RAG moduliu abiems temoms ji galiausiai sukurdavo mišrios pozicijos agentus. Buvo daroma prielaida, jog neutralios personos šaltiniuose buvo nerastos ir sekančiame etape neutrali persona buvo pridedama rankiniu būdu, tai yra aptariama vėliau.

Iteracijų skaičius

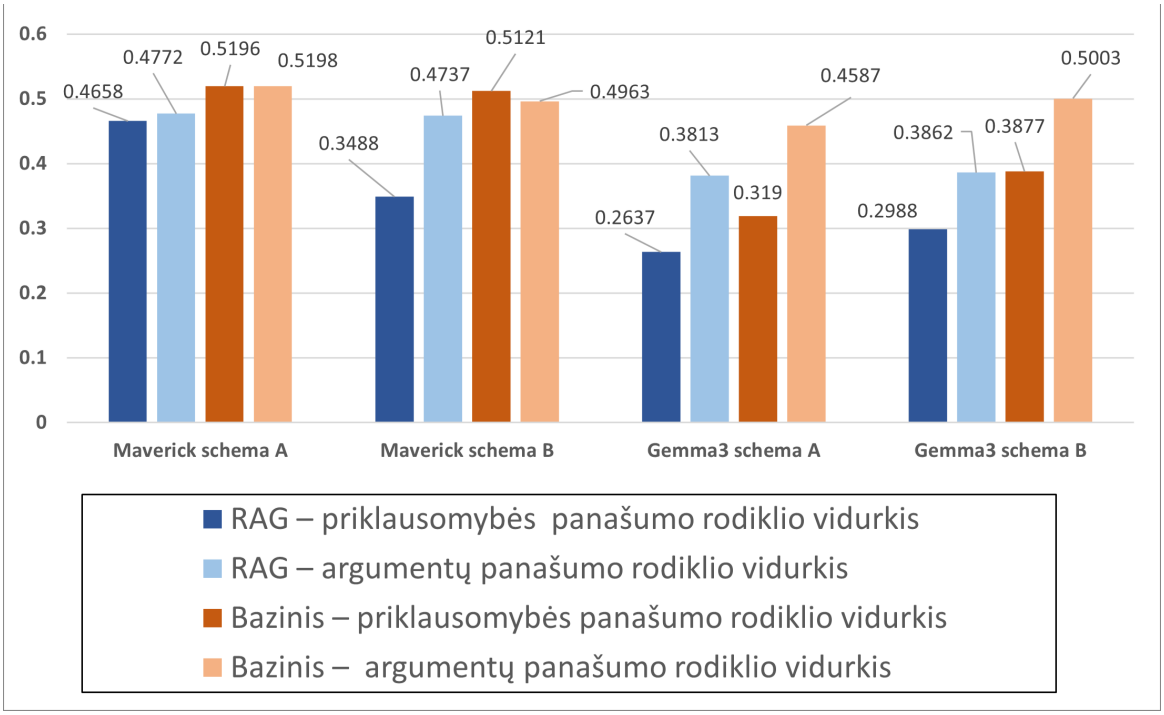
Kiekviena metodo, modelio, schemos bei temos kombinacija – buvo vykdoma **10 iteracijų**. Toks kiekis pasirinktas pastebėjus, jog didesnis iteracijų kiekis reikšmingai nepakeičia rezultato bei buvo siekiama įžvelgti bendrą tendencingumą visose kombinacijose, o ne pavienėse iteracijose, todėl buvo nuspręsta taupyti resursus ir tęsti su mažesniu iteracijų skaičiumi kiekvienai kombinacijai.

6.3.2. Rezultatai

Pirmojo etapo rezultatai yra pirmiausia skaidomi pagal aptartus panašumo rodiklius, tuomet, kiekvienas rodiklis yra vizualizuojamas dviem grafikais: vienu *„LRT“* temai ir vienu partnerystės temai.

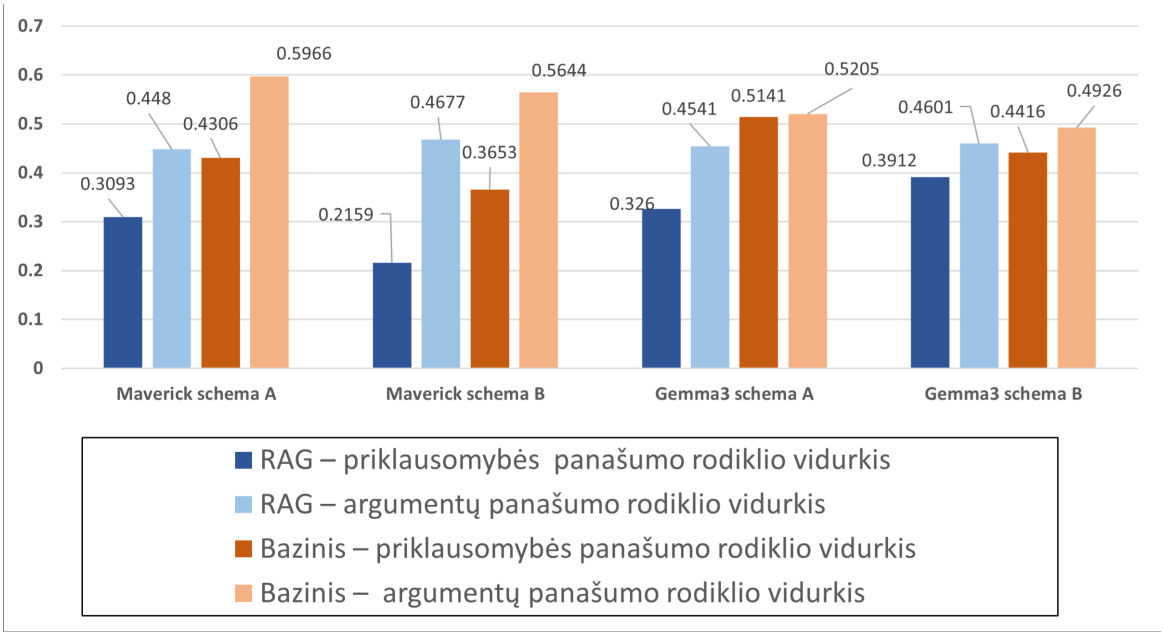
Personų įvairovė iteracijos ribose

Žvelgiant į šio rodiklio rezultatus *„LRT“* temoje, RAG metodas visose keturiose kombinacijose kuria įvairesnes personas nei bazinis metodas – abi rodiklio reikšmės (priklausomybė ir argumentai) yra žemesnės už bazinius, kaip galima matyti grafike 16. Skirtumas yra ryškiausias modelio *Gemma 3* kombinacijose: schemoje A – RAG priklausomybės rodiklis siekia ~0,26, bazinio – ~0,38; schemoje B – atitinkamai ~0,30 ir ~0,39. Tas pats dėsningumas pastebimas ir argumentų panašumo rodiklyje: *Gemma 3* schemoje A RAG reikšmė siekia ~0,38, bazinio – ~0,46; schemoje B – atitinkamai ~0,39 ir ~0,50. *Llama Maverick* modelio kombinacijose skirtumas mažesnis, tačiau išlieka nuoseklus.



16 pav. *Personų įvairovės iteracijos ribose rodiklio grafikas („LRT“ tema)*

Partnerystės temoje tendencija išlieka ta pati – RAG metodas visose kombinacijose sukuria tarpusavyje įvairesnes personas, kaip matoma grafike 17. Ryškiausias skirtumas priklausomybės rodiklyje pastebimas *Gemma 3* schemoje A: RAG reikšmė siekia ~0,33, bazinio – ~0,51, bei *Maverick* schemoje B: atitinkamai ~0,22 ir ~0,37. Argumentų panašumo rodiklyje skirtumas taip pat išlieka nuoseklus visose kombinacijose, išskyrus *Gemma 3* schemą B, kurioje reikšmės artimesnės: RAG ~0,46, bazinis ~0,49. Bendrai abi temos demonstruoja tą patį dėsningumą – RAG grįstos personos yra įvairesnės tiek priklausomybės, tiek argumentų panašumo rodikliuose.

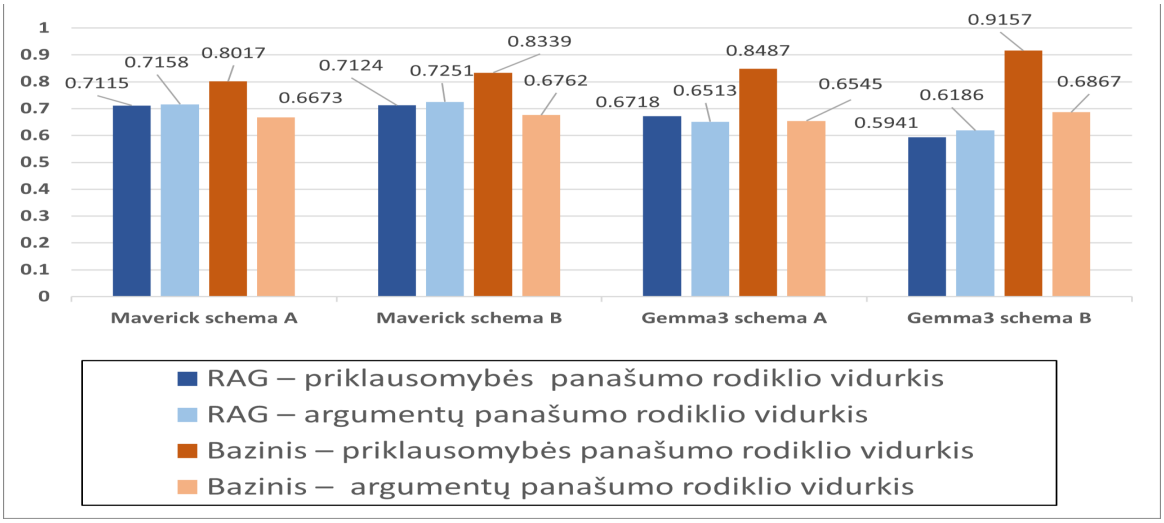


17 pav. *Personų įvairovės iteracijos ribose rodiklio grafikas (partnerystės tema)*

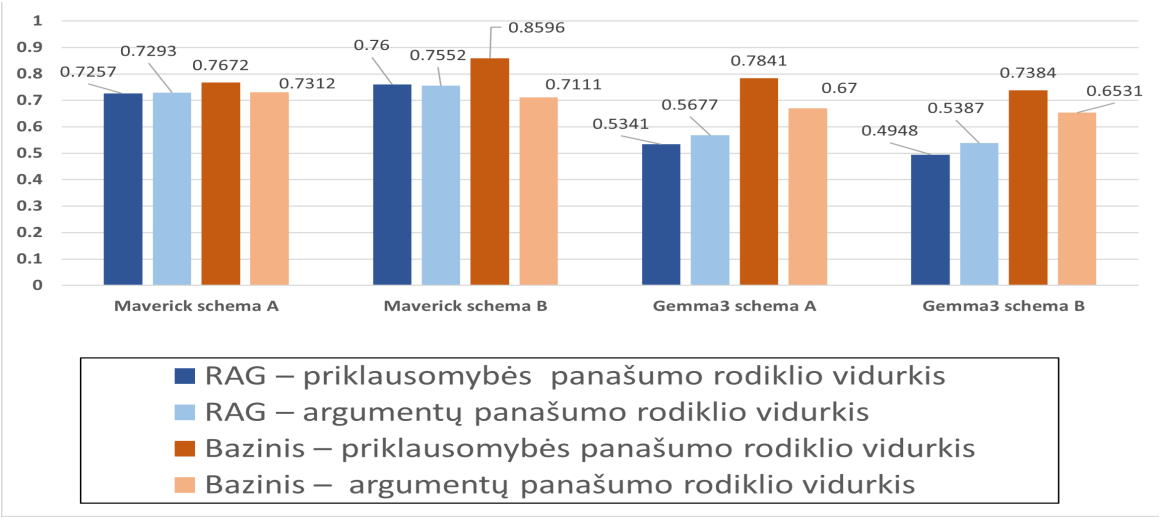
Personų įvairovė tarp iteracijų

Žvelgiant į personų įvairovės tarp iteracijų rodiklio rezultatus, galima išskirti kelis dėsningumus. Pirma, priklausomybės panašumo rodiklis visose aštuoniose kombinacijų yra žemesnis naudojant RAG metodą nei bazinį. Tai sisteminė tendencija, rodanti, jog RAG grįstos personos tarp iteracijų išlaiko didesnę įvairovę priklausomybių laukuose. Taip pat pastebima, jog modelio *Gemma 3* bazinio metodo priklausomybės rodiklis visose kombinacijose yra aukštesnis nei *Maverick* bazinio metodo – skirtumas svyruoja nuo ~0,04 iki ~0,13, kas rodo, jog be išorinio konteksto *Gemma 3* modelis keliose iteracijose sukuria tarpusavyje panašesnes personas nei *Maverick* modelis.

Antra, argumentų panašumo rodiklis bendros sisteminės tendencijos nedemonstruoja – rezultatai svyruoja tarp kombinacijų ir modelių, neleisdami daryti vienareikšmių išvadų.



18 pav. *Personų įvairovės keliose iteracijose rodiklio grafikas („LRT“ tema)*



19 pav. *Personų įvairovės keliose iteracijose rodiklio grafikas (partnerystės tema)*

6.3.3. Išvados

Atsižvelgiant į pirmojo etapo rezultatus galima daryti kelias išvadas. Pirmiausia - personų įvairovės iteracijos ribose rodiklis visose šešiolikoje kombinacijų yra žemesnis naudojant RAG metodą – tai tendencija, rodanti, jog žiniatinklio kontekstas leidžia sukurti semantiškai skirtingesnes personas nei naudojantis tik modelio svoriuose užkoduota informacija, nepriklausomai nuo modelio, schemos ar temos.

Toliau – personų įvairovės tarp iteracijų rodiklio atveju priklausomybės matavimuose RAG metodas taip pat visose aštuoniose kombinacijų porų sukūrė įvairesnes personas, kur skirtumo dydis priklausė nuo modelio. *Gemma 3* baziniu metodu sukurtos personos buvo tarpusavyje panašesnes tarp iteracijų, ko pasekoje skirtumas tarp metodų yra žymiai ryškesnis nei *Llama 4 Maverick* modelio kombinacijose.

Ši išvada yra svarbi atsižvelgiant į antrajame etape tiriamą balsavimo elgseną: jei bazinis metodas jau personų kūrimo stadijoje sukuria tarpusavyje panašias personas – ypač *Gemma 3* modelio atveju – galima kelti hipotezę, jog tai gali sustiprinti [TDR+24] aprašytą konvergacijos reiškinį. RAG metodas, užtikrindamas didesnę personų įvairovę tiek iteracijos ribose, tiek tarp iteracijų priklausomybės lauko atveju, sudaro sąlygas tikrinti, ar skirtingesnės personos lemia ir skirtingą balsavimo elgseną antrajame etape.

6.4. Antrasis etapas – diskusijų ir balsavimo analizė

Antrajame tyrimo etape buvo pasirinkti keturi kintamieji: personų kūrimo metodas (RAG arba bazinis), naudojamas D.K.M., pozicijų schema ir diskusijos tema. Skirtingai nei pirmajame etape, kur schemų buvo dvi, antrajame etape buvo įvestos trys pozicijų schemos, todėl bendras kombinacijų skaičius siekia $3 \times 2^3 = 24$, kurių kiekviena buvo vykdoma 15 iteracijų.

6.4.1. Metodologija

Užklausų kūrimo temperatūra

Visiems agentų diskusijos bei balsavimo žingsniams buvo naudojama D.K.M. išvesties kūrimo temperatūra su reikšme – **1.0**. Toks pasirinkimas priimtas siekiant suderinamumo su šaltinio [TDR+24] eksperimento sąlygomis. Šio darbo autoriai taip pat taikė temperatūros reikšmę 1.0 agentų diskusijoms kurti, argumentuodami tuo, jog aukštesnė reikšmė užtikrina pakankamą iteracijų įvairovę, atsižvelgiant į tai, jog D.K.M. nėra deterministiški.

Diskusijos konfigūracijos parametrai

Diskusijos eigai valdyti buvo naudojami trys jau aptarti sistemos parametrai: diskusijos žingsnių skaičius, trumpalaikės atminties dydis ir ilgalaikės atminties atnaujinimo intervalas. Visoms metodo, modelio, schemos bei temos kombinacijoms buvo taikomos tos pačios reikšmės:

- **Diskusijos žingsnių skaičius** (`DEBATE_ROUND_COUNT`) = `11` – diskusijos žingsnių skaičius pasirinktas taip, kad kiekvienas iš trijų agentų tris kartus pasisakytų kalbėjimo viršūnėje. Vidurinis ir paskutinis balsavimas skaičiuojamas kartu, todėl papildomai pridėti du žingsniai.
- **Ilgalaikės atminties atnaujinimo intervalas** (`LONG_MEMORY_UPDATE_INTERVAL`) = `5` – buvo pasirinktas santykinai didelis intervalas lyginant su bendru diskusijos žingsnių skaičiumi, kadangi šiame tyrime atminties mechanizmo poveikio analizė nebuvo atlikta.
- **Trumpalaikės atminties dydis** (`MEMORY_WINDOW_SIZE`) = `5` – paliktas iš sistemos kūrimo proceso ir yra didelis dėl tos pačios priežasties kaip ir ilgalaikės atminties intervalas.

Agentų personų pozicijų schemos

Antrajame etape buvo naudojamos trys pozicijų schemos, kiekviena su trimis agentais:

- **schema A (palaiko $\times$ 2, prieštarauja $\times$ 1)** – ši schema buvo perkelta iš pirmojo etapo ir naudojama kaip atraminis matavimo taškas, kuriame visi trys agentai turi aiškiai išreikštą poziciją.
- **schema C (palaiko $\times$ 1, prieštarauja $\times$ 1, neutralus $\times$ 1)** – ši schema pasirinkta atsižvelgiant į šaltinio [TDR+24] eksperimentą, kuriame autoriai taip pat sudarė trijų agentų diskusiją iš dviejų nustatytą poziciją palaikančių dalyvių (respublikonas ir demokratas) bei trečio, neutralaus agento, kurio paskirtis – atspindėti modelio vidinį polinkį be papildomos pozicijos įvedimo.
- **schema D (prieštarauja $\times$ 2, neutralus $\times$ 1)** – šios schemos pasirinkimą motyvuoja palyginimas su schema C, bet vietoj palaikančio agento yra įvedamas antras prieštaraujantis. Tokiu būdu sukuriama nesubalansuota aplinka, leidžianti vertinti, kaip neutralaus agento elgsena kinta, kai diskusijoje dalyvauja tik vieną poziciją palaikantys agentai.

Neutralaus agento įgyvendinimas

Kaip jau aptarta pirmojo etapo skyriuje, RAG modulio dublikatų šalinimo žingsnyje neutralios pozicijos personos abiems temoms galiausiai virsdavo mišrios pozicijos personomis. Todėl schemose C ir D, kurios reikalavo agento su neutralia persona, ji buvo pridedama rankiniu būdu, naudojant šį šabloną:

```
DEFAULT_PERSONA = {
    "name": "ūRta",
    "affiliation": "Lithuanian citizen",
    "role_desc": "I am a Lithuanian citizen.",
    "keypoints": [],
    "background": "An ordinary Lithuanian citizen.",
    "stance": "neutral",
    "sources": [],
}
```

Įvesties šablonas 10: Neutralaus agento personos šablonas

Ši persona visose iteracijose turėjo identišką vardą „Rūta“ su tuščiu argumentų (`keypoints`) rinkiniu, o personos aprašymas buvo (`role_desc`) suformuluotas maksimaliai neutraliai, siekiant nesusieti personos su jokia konkrečia pozicija temos atžvilgiu. Toks sprendimas atitiko šaltinio [TDR+24] neutralaus agento apibrėžimą.

Iteracijų skaičius

Kiekviena metodo, modelio, schemos bei temos kombinacija buvo vykdoma 15 iteracijų. Lyginant su pirmuoju etapu, kuriame iteracijų skaičius buvo 10, antrajame etape iteracijų skaičius buvo šiek tiek padidintas atsižvelgiant į tai, jog balsavimo elgsenos rodikliai pasižymi didesnių triukšmu tarp iteracijų nei personų panašumo rodikliai – kiekvienoje iteracijoje agentai gali kurti reikšmingai skirtingas diskusijas. Nepaisant to, abiejuose etapuose buvo siekiama identifikuoti bendras tendencijas visose kombinacijose – pavieniai svyravimai keliose iteracijose iš 15 nenusvėrė bendrų dėsningumų.

6.4.2. Rezultatai

Antrojo etapo rezultatai yra skaidomi pagal skyriuje 5.6.2. aptartus balsavimo elgsenos rodiklius. Balsų atitikimo pozicijoms rodiklis pateikiamas trimis grafikais, atitinkančiais pradinį, vidurinį ir galutinį diskusijos etapą, kuriuose visos schemos vaizduojamos kartu. Balsų pozicijos kaitos rodiklis toliau skaidomas pagal stebėjimo lygmenį – grupės vidutinė pozicija arba atskirų agentų pozicija – bei pagal schemą. Tuomet schema A, kaip atraminis matavimo taškas su aiškiai poziciją išreiškiančiais agentais, nagrinėjama atskirai, o schemos C ir D, kuriose dalyvauja neutralus agentas, lyginamos tarpusavyje. Kiekvieną rodiklį vaizduojantis grafikas apima visas keturias modelio ir temos kombinacijas.

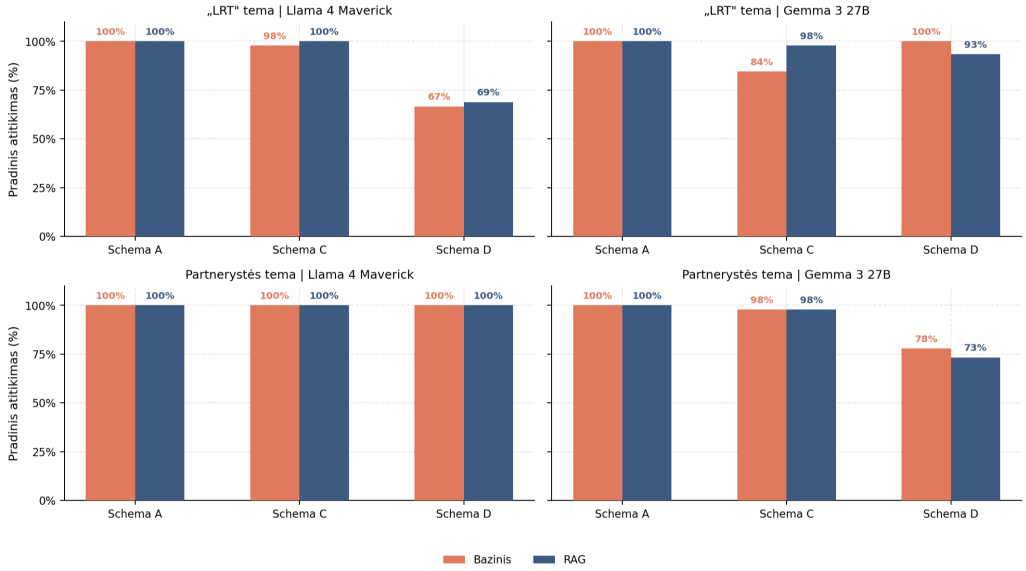
Balso pozicijos kaitos tarp etapų rodiklio rezultatai atskirai nepateikiami, nes jo įžvalgos sutapo su grupės vidutinės pozicijos bei atskirų agentų pozicijų įžvalgomis ir jis buvo laikomas pertekliniu.

Balsų atitikimas pozicijoms

Pirmasis nagrinėjamas rodiklis – agentų balso atitikimas jų priskirtai pozicijai pradiniame, viduriniame ir galutiniame balsavimo etapuose.

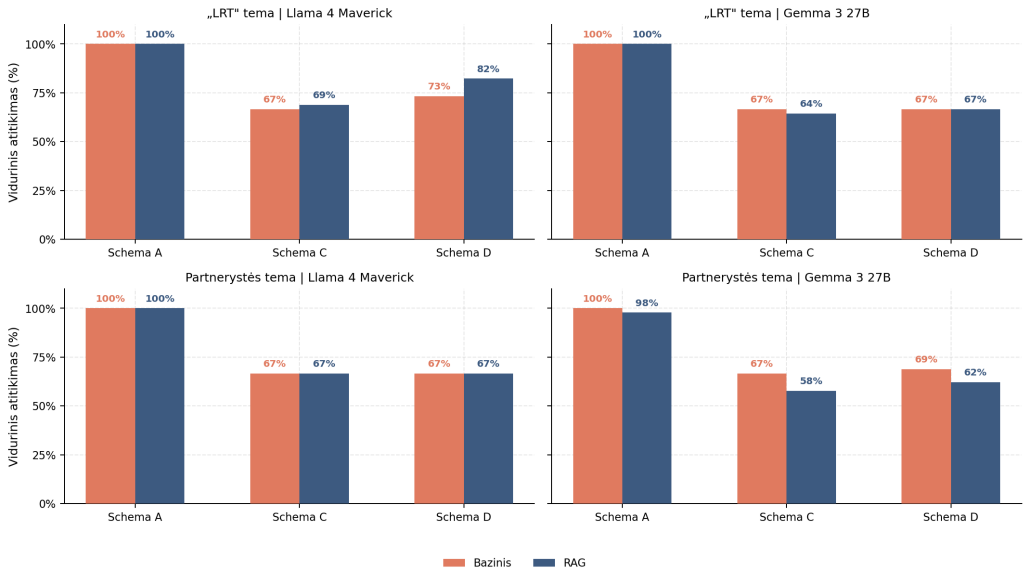
Pradinio balsavimo etape, kurio sutapimo rodiklį iliustruoja grafikas 20, schemoje A visose keturiose modelio ir temos kombinacijose abiejų metodų atitikimas siekia 100%. Schemose C ir D reikšmės taip pat išlieka aukštos – 93% ar daugiau – išskyrus tris atvejus: *„LRT“* temos *Gemma 3 27B* modelio schemoje C bazinis metodas pasiekia 84%, o *„LRT“* temos *Llama 4 Maverick* modelio schemoje D abiejų metodų reikšmės yra 67% – 69%, o *Gemma 3 27B* 73% – 78% . Šiais atvejais nukrypimą lemia neutralus agentas, kurio elgsena bus aptariama vėliau. Verta atkreipti dėmesį, jog neutralios pozicijos atitikimo kriterijus yra griežtesnis nei kitų pozicijų: rodiklyje neutraliam agentui yra priskiriamas tik vienas iš penkių balsavimo variantų, tuo tarpu palaikančiam ar oponuojančiam agentui – du. Nepaisant šio fenomeno, aukštos pradinio etapo reikšmės leidžia teigti, jog agentai

pradiniame balsavime išreiškia jų personoje nurodytai pozicijai atitinkantį balsą, to pasekoje galima teigti jog personų kūrimo ir balsavimo moduliai veikia kaip tikėtasi.

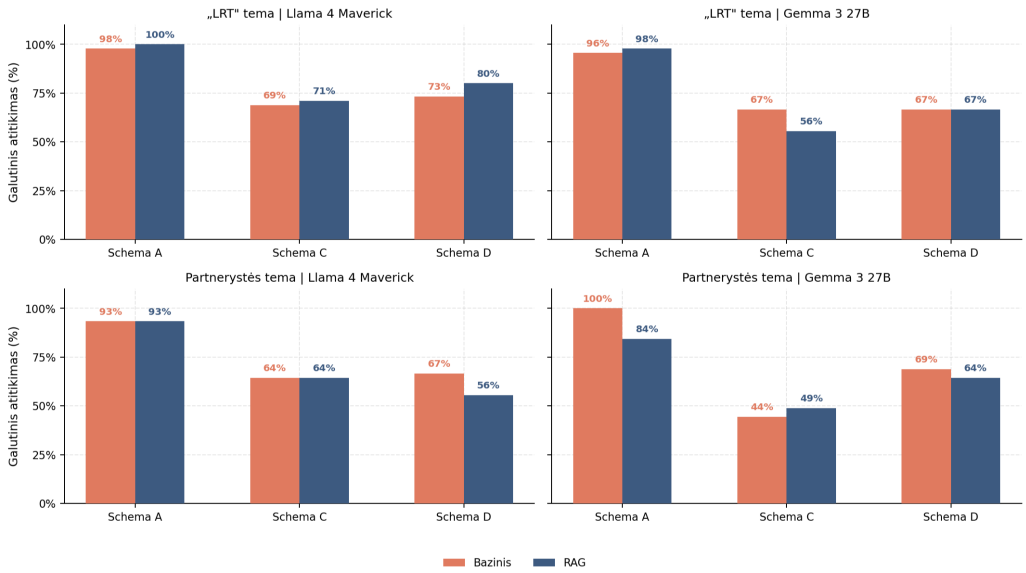


20 pav. *Pradinių balsų atitikimo priskirtoms pozicijoms rodiklio grafikas*

Vidurinio ir galutinio balsavimo etapuose, kuriuos atvaizduoja grafikai 21 ir 22, schemoje A abiejų metodų atitikimas visose keturiose kombinacijose išlieka praktiškai nepakitęs, lyginant su pradiniu etapu – reikšmės svyruoja intervale 84% – 100%. Tai rodo, jog agentų pozicijos iš esmės nepasikeičia, bet metrika nefiksuoja jos sušvelnėjimo, kuris aptariamas vėliau. Schemose C ir D, kuriose dalyvauja neutralus agentas, atitikimas viduriniame etape pastebimai sumažėja – reikšmės nukrenta į 58%–82% intervalą, šis sumažėjimas išlieka ir galutiniame etape: reikšmės nesikeičia arba keičiasi nežymiai. Toks dėsningumas atitinka [TDR+24] autorių pastebėjimą, jog didžioji dalis nuomonių pokyčių diskusijose įvyksta ankstyvuosiuose etapuose. Lyginant RAG ir bazinį metodus, grafikai neatskleidžia jokios nuoseklios tendencijos – skirtumai tarp metodų yra nedideli ir nenuoseklūs.



21 pav. *Vidurinių balsų atitikimo priskirtoms pozicijoms rodiklio grafikas*



22 pav. *Galutinių balsų atitikimo priskirtoms pozicijoms rodiklio grafikas*

Grupės pozicijos kaita – schema A

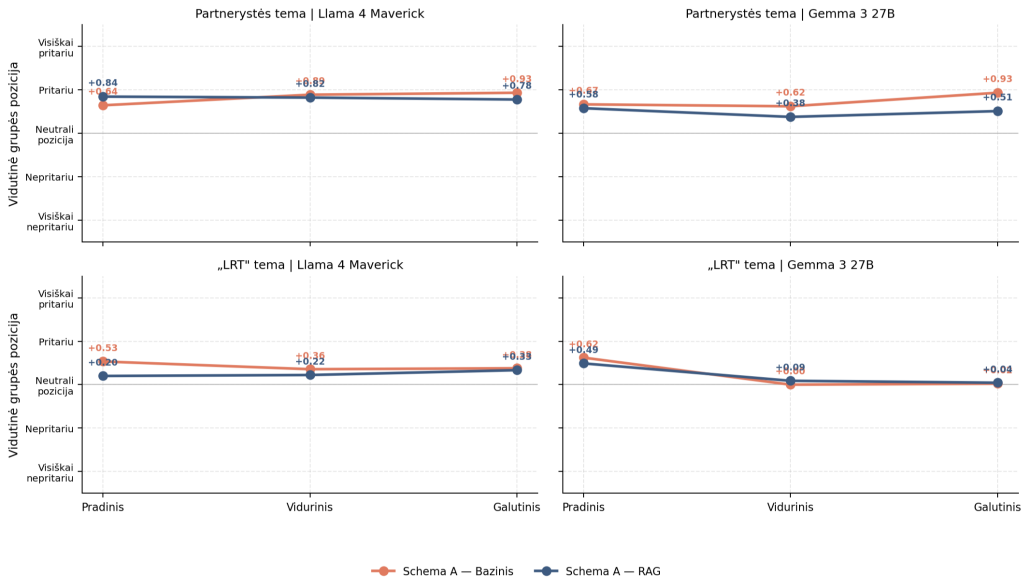
Toliau nagrinėjamas agentų balsų pozicijų pokyčio rodiklis, tiek visos grupės tiek pavienių agentų atvejais. Grafikas 23 vaizduoja vidutinę grupės balso poziciją schemoje A – visose kombinacijose.

Pirmiausia pastebima, jog RAG ir bazinio metodo trajektorijos visose kombinacijose yra praktiškai identiškos – tai papildo atitikimo rodiklio išvadą, kad personų kūrimo metodas balsavimo elgsenai nuoseklios įtakos neturi.

Papildomai pastebimas skirtumas tarp modelių: *Gemma 3 27B* kombinacijose grupės pozicija kinta labiau nei *Llama 4 Maverick* kombinacijose. Ypač *„LRT“* temos kombinacijose, kur *Gemma 3 27B* vidutinė grupės pozicija pradiniame etape nukrenta nuo $(+0{,}49)$ – $(+0{,}62)$ iki $(0{,}00)$ – $(+0{,}09)$ viduriniame etape ir ten stabilizuojasi. *Llama 4 Maverick* toje pačioje temoje pokytis yra kuklesnis – nuo $(+0{,}20)$ – $(+0{,}53)$ iki $(+0{,}22)$ – $(+0{,}38)$ – ir galutinė pozicija išlieka arčiau pradinės. Partnerystės temoje šis kontrastas mažiau ryškus, tačiau *Gemma 3 27B* ir čia demonstruoja didesnį svyravimą tarp etapų. Norint geriau suprasti vidinius nuomonių pokyčius toliau nagrinėjami atskiri agentų balsai schemoje A.

Atskirų agentų pozicijų kaita – schema A

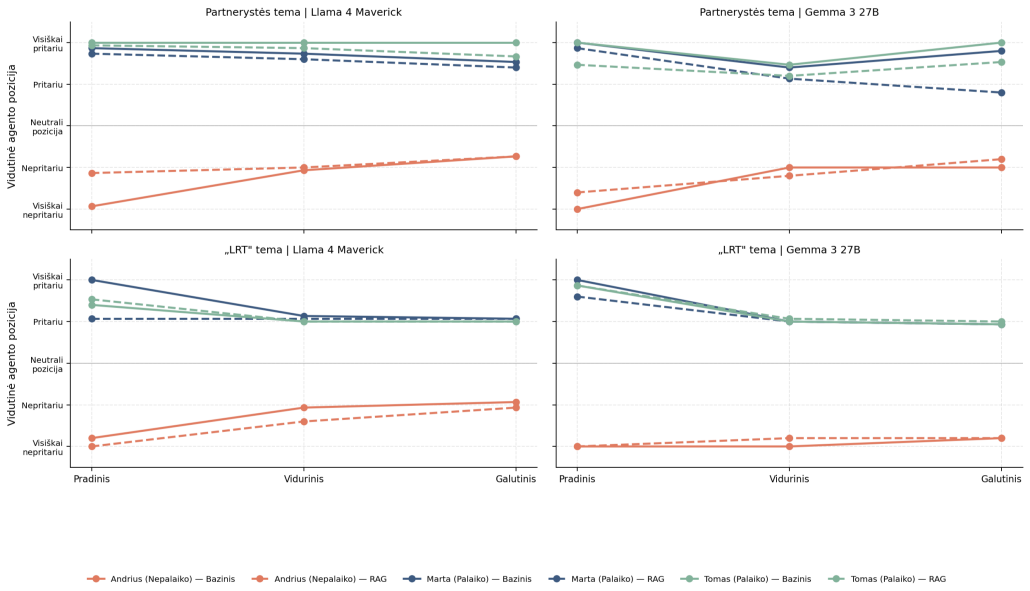
Grafikas 24 atskleidžia, kad grupės lygio pokytis kyla ne iš vienos pozicijos agentų elgsenos – abiejų pusių agentai sušvelnina savo pozicijas diskusijos eigoje. Palaikantys agentai *Marta (Palaiko)* ir *Tomas (Palaiko)* daugelyje kombinacijų švelnina savo balsavimo pozicijas nuo „Visiškai pritariu“ iki „Pritariu“, prieštaraujantis agentas *Andrius (Nepalaiko)* analogiškai – nuo „Visiškai nepritariu“ link „Nepritariu“. Išimtis – partnerystės temos *Gemma 3 27B* kombinacijose, kuriose agentų pozicijos viduriniame etape šiek tiek svyruoja, tačiau galutinėje pozicijoje vis tiek pastebimas artėjimas link palaikymo. Kaip ir grupės pozicijų kaitos rodiklyje, RAG ir bazinio metodo trajektorijos išlieka prak-



23 pav. *Grupės agentų balsų pokyčio rodiklio grafikas (schema A)*

tiškai identiškos visose kombinacijose – pavienių agentų lygmenyje šis dėsningumas nekinta.

Pastebėtas abipusis balsų pozicijų sušvelnėjimas suteikia papildomą motyvaciją tirti schemas, kuriose neutralus agentas yra pradinis, o ne suformuotas diskusijos. Galima kelti klausimą, ar pradinis neutralus agentas konverguos į grupės daugumos poziciją, išliks neutralus ar demonstruos kitokią elgseną – tai ir tikrinama schemose C ir D.



24 pav. *Atskirų agentų balsų pokyčio rodiklio grafikas (schema A)*

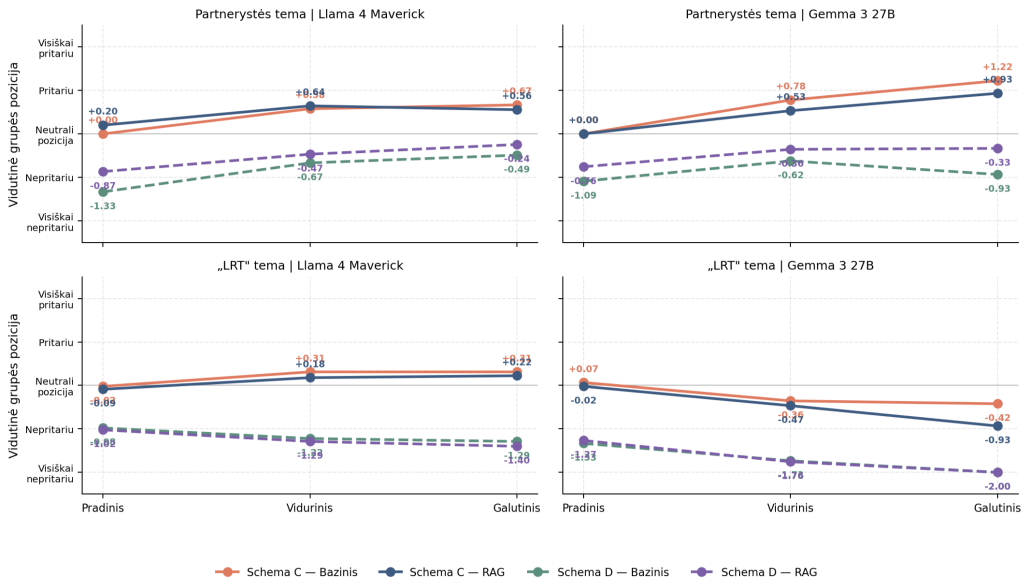
Grupės pozicijos kaita – schemos C ir D

Grafikas 25 vaizduoja vidutinę grupės balso poziciją schemų C ir D kombinacijose. Kaip ir schemoje A, RAG ir bazinio metodo trajektorijos nesudaro reikšmingo dėsningumo – personų kūrimo

metodo įtaka grupės pozicijos dinamikai ir čia nepastebima.

Schemos C trajektorijos atskleidžia skirtingą modelių elgseną toje pačioje temoje. Partnerystės temoje abiejų modelių grupės pozicija kyla per visus etapus – nuo neutralios pradiniame etape iki teigiamos galutiniame, kas rodo, jog modeliai šioje temoje turi bendrą polinkį į palaikymą. *„LRT“* temoje šis vieningumas išnyksta: *Llama 4 Maverick* trajektorija kyla nuo $(-0{,}02)$ – $(-0{,}09)$ iki $(+0{,}22)$ – $(+0{,}31)$, o *Gemma 3 27B* krenta nuo $(-0{,}02)$ – $(+0{,}07)$ iki $(-0{,}42)$ – $(-0{,}93)$. Tai gali reikšti, jog modeliai šioje temoje turi skirtingus, vienas kitam priešingus polinkius – vienas linkęs į palaikymą, kitas į oponavimą. Papildomai šį polinkį tvirtina ir aptarta A schema, kurioje, nors pokyčiai mažesni, bet pokyčio kryptis sutampa.

Schemoje D daroma prielaida, jog oponuojančių agentų daugumą turėtų traukti bendrą grupės poziciją žemyn – tačiau partnerystės temoje tai nepasireiškia: abiejų modelių trajektorijos kyla, kas dar kartą patvirtina šios temos palaikymo polinkio stiprumą užkoduotą modelio svoriuose. *„LRT“* temoje schemos D poveikis yra kitoks. *Llama 4 Maverick* atveju oponuojančių daugumos struktūra apverčia trajektoriją – ten kur schemoje C grupės pozicija kilo, schemoje D ji krenta. *Gemma 3 27B* atveju schema D tik sustiprina jau schemoje C matomą žemyn krypstančią trajektoriją – galutinė reikšmė pasiekia -2,00, t.y. visišką konvergavimą į „Visiškai nepritariu“ balsą, kas yra ekstremaliausia stebėta reikšmė visuose eksperimentuose. Tai vėlgi demonstruoja A schemoje pastebėtą fenomeną, kuomet *Gemma 3 27B* demonstruoja didesnį balsavimo pozicijos pokytį lyginant su modeliu *Llama 4 Maverick*.



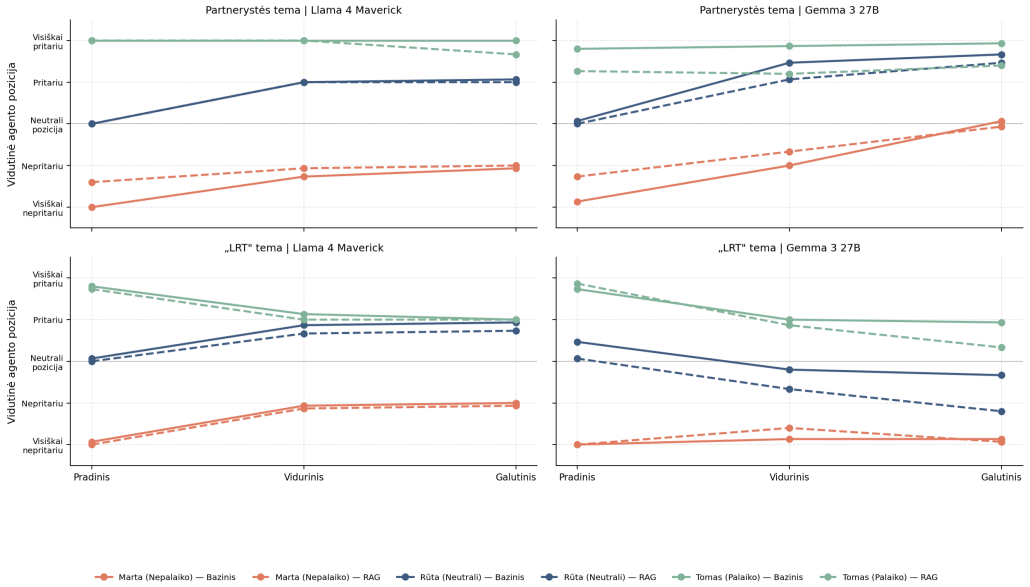
25 pav. *Grupės agentų balsų pokyčio rodiklio grafikas (schemos C ir D)*

Atskirų agentų pozicijų kaita – schema C

Žvelgiant į atskirų agentų pozicijų kaitą schemoje C, grafike 26 galima matyti, jog partnerystės temoje palaikantis agentas *Tomas (Palaiko)* išlaiko aukštą poziciją per visus etapus, o neutralaus

agento *Rūta (Neutrali)* ir oponuojančio agento *Marta (Nepalaiko)* balsai juda jo kryptimi – tai paaiškina stebimą grupės vidurkio augimą. *Gemma 3 27B* modelio atveju šis poslinkis yra ryškesnis nei *Llama 4 Maverick* atveju, kas atitinka anksčiau pastebėtą skirtumą balsavimo kaitos intensyvume.

„LRT“ temoje, kaip pastebėta ir grupės rodiklyje, agentų elgsena skiriasi priklausomai nuo modelio. *Llama 4 Maverick* atveju palaikantis agentas *Tomas (Palaiko)* žemina savo balsavimo poziciją, o neutralus *Rūta (Neutrali)* bei oponuojantis agentas *Martos (Nepalaiko)* kelia savo balsą jo link – taigi grupės vidurkio augimas yra sąlygotas ne palaikančio agento balsavimo stiprėjimu, o oponuojančio ir neutralaus agentų poslinkiu palaikymo kryptimi. Tai gali reikšti, jog modelio polinkis šiai temai nėra stiprus arba pasireiškia anksčiau aptartas konvergavimo į centrinę poziciją reiškinys. *Gemma 3 27B* modelio kombinacijose palaikantis agentas *Tomas (Palaiko)* ir neutralus *Rūta (Neutrali)* reikšmingai žemina pozicijas, tuo tarpu oponuojantis agentas *Marta (Nepalaiko)* išlaiko tvirtą oponavimo poziciją – tai lemia stebimą ryškų grupės vidurkio kritimą.



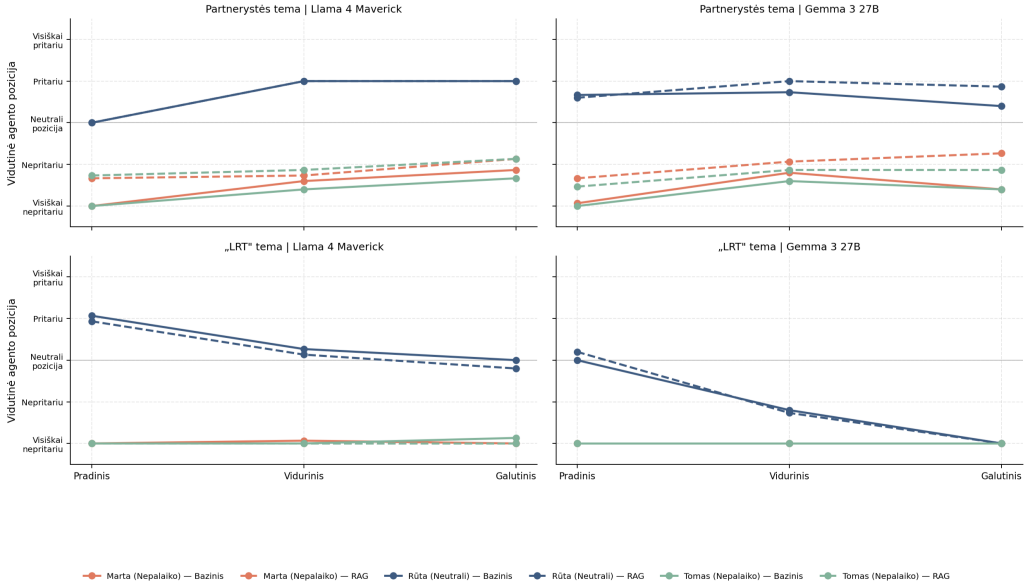
26 pav. *Atskirų agentų balsų pokyčio rodiklio grafikas (schema C)*

Atskirų agentų pozicijų kaita – schema D

Grafikas 27 atskleidžia, kad schemoje D, kurioje oponuojančių agentų dauguma teoriškai turėtų patraukti neutralaus agento balsus žemyn, partnerystės temoje ši prielaida nepasiteisina. Vietoj to neutralus agentas *Rūta (Neutrali)* juda palaikymo kryptimi, o oponuojantys agentai *Marta (Nepalaiko)* ir *Tomas (Nepalaiko)* taip pat artėja link palaikymo, *Gemma 3 27B* atveju neutralus agentas net pradeda su palaikymo balsu. Tai patvirtina anksčiau stebėtą modelio polinkį, kuris yra pakankamai stiprus, kad neutralizuotų schemos struktūros bei kartu ir RAG poveikį.

Nepaisant to, *„LRT“* temoje prielaida pasitvirtina. *Llama 4 Maverick* atveju neutralus agentas *Rūta (Neutrali)* nuosekliai juda oponavimo kryptimi – nuo „Pritariu“ iki beveik neutralios pozicijos – kas prieštarauja jo trajektorijai schemoje C ir atitinka schemoje A stebėtą modelio polinkį šioje

temoje. *Gemma 3 27B* atveju tas pats mechanizmas pasireiškia daug ryškiau – neutralus agentas per visus etapus nuosekliai artina savo balsą oponavimo kryptimi, galiausiai sukonverguodamas pozicijoje – „Visiškai nepritariu“, kartu su oponuojančiais agentais.



27 pav. *Atskirų agentų balsų pokyčio rodiklio grafikas (schema D)*

6.4.3. Išvados

Antrojo etapo rezultatai leidžia daryti kelias išvadas. Pirma, nei balsų atitikmens personos pozicijai, nei grupės ar pavienių agentų pozicijų kaitos rodikliai neatskleidžia nuoseklaus skirtumo tarp RAG ir bazinio metodo. Tai reiškia, jog antrojo etapo balsavimo elgsena yra nepriklausoma nuo personų kūrimo metodo, ir kartu papildo pirmojo etapo išvadą: nors RAG metodas sukuria įvairesnes personas, tai neturi išmatuojamo efekto diskusijos rezultatams.

Antra, *Gemma 3 27B* visose schemose ir temose demonstruoja didesnį balsavimo pozicijos pokytį nei *Llama 4 Maverick* – tai nuoseklus dėsningumas, nepriklausantis nuo schemos struktūros ar temos. Siekiant įvertinti: ar tai modelio parametrų kiekio, ar architektūros, ar kito kintamojo efektas, reikėtų atlikti papildomus tyrimus, kurie išeina už šio darbo ribų.

Trečia, diskusijų dinamiką lemiančiu veiksniu galima laikyti pasirinkto modelio ir temos kombinacija, o ne schemos struktūrą ar personų kūrimo metodą. Partnerystės temoje grupės pozicija visose schemose ir abiejuose modeliuose kyla palaikymo kryptimi – net kai schemos struktūra (D) sudaro oponuojančių agentų daugumą. *„LRT“* temoje bendro polinkio nėra: *Llama 4 Maverick* trajektorija kyla, išskyrus vieną kombinaciją, *Gemma 3 27B* – krenta, kas rodo, jog modeliai šiai temai turi skirtingus ir vienas kitam priešingus polinkius.

Galiausiai, schemose C ir D neutralaus agento trajektorija atsako į pirmojo etapo pabaigoje iškeltą klausimą – ar pradinis neutralus agentas konverguos į grupės daugumos poziciją, išliks neut-

ralus ar demonstruos kitokią elgseną. Rezultatai rodo, jog neutralus agentas atspindi dominuojantį modelio polinkį: partnerystės temoje juda palaikymo kryptimi, *„LRT“* temoje – oponavimo. Schemos struktūra šį procesą sustiprina arba susilpnina, tačiau nepakeičia jo krypties, išskyrus *Llama 4 Maverick* schemoje D, kurioje oponuojančių daugumos struktūra pakankamai stipri, kad apverstų schemoje C stebėtą trajektoriją, bet svarbu pastebėti, jog neutralus agentas pradeda su pritariančia pozicija 14 iš 15 iteracijų, ne neutralia.

7. Išvados

Šio darbo tikslas buvo sukurti ir įvertinti agentais paremtą diskusijų sistemą, kurioje agentų personos būtų kuriamos pasitelkiant RAG metodą, bei palyginti šį personų kūrimo būdą su baziniu metodu, naudojančiu tik modelio svoriuose užkoduotą informaciją.

Literatūros analizė atskleidė, jog D.K.M. grįstos visuomenės simuliacijos turi potencialo, tačiau šiuo metu negali būti laikomos patikimu įrankiu visuomenės procesams modeliuoti. Pagrindiniai apribojimai, kaip aptarta šaltiniuose, kyla iš pačių modelių – šališkumo, nepakankamos elgsenos įvairovės bei negebėjimo reprezentuoti mažesnių demografinių grupių bei dėl pačių sistemų įgyvendinimo trūkumų. Atsižvelgiant į šiuos pastebėjimus, darbe buvo priimtas sprendimas neprilyginti D.K.M. agentų realiems žmonėms, o tirti daugiagentės diskusijų sistemos elgseną ir agentų tarpusavio sąveiką kaip atskirą reiškinį. Tokia sistema ateityje galėtų veikti kaip pagalbinis apklausų įrankis arba kaip vienas iš platesnės visuomenės simuliacijos modulių. Yra teigiama, jog abu panaudojimo atvejai reikalauja suprasti pačios sistemos elgsenos dėsningumus bei problematika, kas ir sudaro šio tyrimo pagrindą.

Šiam tyrimui įgyvendinti buvo sukurta eksperimentinė diskusijų sistemos aplinka, realizuota kaip bazinės sistemos išplėtimas. *„LangGraph“* bibliotekos suteikiama grafo logika leido aiškiai atskirti diskusijos koordinavimą nuo agentų veikimo, o modulinė struktūra sudarė sąlygas papildyti sistemą RAG grįstu personų kūrimo moduliu, vertinimo moduliu bei naujais personos objektų apibrėžimais. Lanksti konfigūracija leido keisti personų kūrimo metodą, modelį, pozicijų schemą bei temą – tai sudarė pagrindą antrojo etapo eksperimentams. Vertinimo modulis apėmė tiek personų įvairovės, tiek balsavimo elgsenos rodiklius, taip sudarant sąlygas dviejų etapų kiekybinei analizei.

Pirmojo etapo rezultatai parodė, jog RAG metodas visose šešiolikoje kombinacijų sukūrė semantiškai įvairesnes personas iteracijos ribose, o priklausomybės lauko įvairovė tarp iteracijų taip pat buvo aukštesnė. Tai leido tęsti tyrimą antrajame etape – siekiant įvertinti ar šis skirtumas sudaro efektą diskusijoje. Šalia personų įvairovės skirtumo, pirmasis etapas atskleidė ir RAG modulio apribojimą – abiejose temose dublikatų šalinimo žingsnis pavertė neutralios pozicijos personas mišrios pozicijos personomis, dėl to neutralus agentas sekančiose schemose buvo pridedamas rankiniu būdu. Tai rodo, jog D.K.M. naudojimas apdoroti žiniatinklio paieškos grąžinamiems duomenims, kuomet yra siekiama išgauti neutralios pozicijos personą – yra sudėtingas uždavinys, kuris riboja pilnavertišką RAG panaudojimą šiame tyrime.

Antrojo etapo rezultatai atskleidė, jog minėtas pirmojo etapo skirtumas nesudarė išmatuojamo efekto balsavimo elgsenoje: nei balsų atitikimo rodiklis, nei grupės pozicijos ar pavienių agentų balsų pozicijos rodikliai neatskleidė nuoseklaus skirtumo tarp RAG ir bazinio metodo nei vienoje iš 24 kombinacijų. Tai rodo, jog didesnis personų semantinis skirtumas bei išorinis kontekstas nereiškia skirtingos balsavimo elgseno daugiaagentėje diskusijoje. Papildomai pastebėta, jog didžioji dalis

balsavimo pokyčių įvyko ankstyvuosiuose diskusijos etapuose – vėlesniuose etapuose pozicijų kaita buvo minimali, kas atitiko darbo [TDR+24] pastebėjimą, kuris teigė, jog pagrindinė agentų balsavimo pozicijų kaita įvyksta diskusijų pradžioje.

Pagrindine antrojo etapo išvada tapo pastebėtas modelio šališkumo poveikis – diskusijų eigoje agentų balsai konvergavo modelio svoriuose užkoduoto šališkumo kryptimi, nepriklausomai nuo jiems priskirtos pozicijos ar personų kūrimo metodo, o konvergavimo kryptis ir intensyvumas priklausė nuo naudojamo modelio ir diskusijos temos. Buvo pastebėta tik viena kombinacija, kurioje schema sudarė pastebimą poveikį neutraliam agentui, bet pirminė agento pozicija čia irgi buvo šališka. Šis teiginys atitinka darbo [TDR+24] autorių išvadas, kuriose analogiškas konvergavimo reiškinys buvo užfiksuotas skirtinguose modeliuose ir temose. Papildomai pastebėta, jog skirtingi modeliai toje pačioje temoje demonstravo skirtingą konvergavimo intensyvumą – tačiau norint nustatyti, kuris kintamasis tai lemia, reikalingas tolesnis tyrimas.

Apibendrinant, darbe sukurta eksperimentinė aplinka buvo tinkama hipotezėms tikrinti, tačiau iškelta hipotezė, jog RAG grįstos personos lems skirtingą balsavimo elgseną nepasitvirtino – dominuojančiu veiksniu išliko modelių svoriuose užkoduotas šališkumas, o ne personų kūrimo metodas bei išorinis kontekstas. Šių išvadų pasekoje, galima teigti rekomendaciją – kuriant panašias D.K.M. grįstas sistemas, ypač tas, kuriomis siekiama modeliuoti žmogaus/visuomenes elgseną ar jos dalį, būtina iš anksto įvertinti ir pačių modelių elgsenos dėsningumus. Šio panaudojimo atvejui skirtose sistemose, ypač svarbu įvertinti šališkumą, bet svarbu jį vertinti ir naudojant D.K.M. kasdieniams poreikiams. Tai, jog šiame darbe pasiūlytas metodas šio šališkumo nesumažino, nereiškia, jog tai yra neįmanomas uždavinys, tikimasi, jog tolimesni tyrimai gali rasti metodą šiai problemai išspręsti, išlaikant modelio svoriuose sukauptą naudinga visuomenės dėsningumą.

8. Apribojimai ir ateities perspektyvos

Šio darbo svarbiausia išvada – modelio šališkumas egzistuoja, yra identifikuojamas ir šiame tyrime nebuvo suvaldytas. Į tai galima žvelgti kaip į atspirties tašką tolimesniems tyrimams. Žemiau aptariami šio tyrimo apribojimai bei galimos ateities tyrimo kryptys.

Pirmasis apribojimas susijęs su neištirtais sistemos konfigūracijos kintamaisiais. Šiame darbe buvo fiksuoti tokie parametrai kaip modelio įvesties šablonai , diskusijos ilgis, agentų atminties dydis bei kiti sistemos nustatymai. Tolimesniuose tyrimuose šie parametrai galėtų būti įtraukti kaip papildomi kintamieji – tai leistų labiau suprasti jų poveikį balsavimo elgsenai.

Antrasis apribojimas susijęs su sistemos kintamaisiais, kurie šiame darbe nebuvo nagrinėti, tačiau yra aptariami kituose šaltiniuose. Tai tokie kintamieji kaip: naudojama modelio įvesties kalba, agentų tarpusavio bendravimo metodas ar eilės tvarka, kurie taip pat gali daryti poveikį diskusijos elgsenai. Ateities tyrimai, atsižvelgiantys į šiuos veiksnius, galėtų papildyti šio darbo rezultatus ir suteikti platesnį vaizdą.

Trečiasis apribojimas – diskusijų temų pasirinkimas. Jos buvo parinktos, siekiant tirti Lietuvos kontekstą, bet tyrimo metu nebuvo atliktas atskiras palyginimas su kitų šalių ar konteksto temomis. Todėl negalima teigti, jog gauti rezultatai yra būdingi būtent Lietuvos kontekstui, ar pasireikštų analogiškai su bet kuriomis kitomis temomis. Šiam klausimui atsakyti reikėtų papildomo tyrimo, kuriame ta pati sistemos konfigūracija būtų taikoma skirtingo geografinio ar kultūrinio konteksto temoms.

Galiausiai, analogiškas apribojimas galioja ir naudojamiems modeliams. Šiame darbe buvo pasirinkti du modeliai su skirtinga architektūra bei parametrų skaičiumi. Tačiau šiuo metu galimų D.K.M. architektūrų, parametrų kiekių, apmokymo duomenų bei kitų kintamųjų spektras yra itin platus. Tai reiškia, jog šiame darbe gautos išvados negali būti apibendrintos visiems modeliams. Tolimesni tyrimai, apimantys platesnį modelių pasirinkimą, galėtų padėti nustatyti, kokios modelio charakteristikos turi didžiausią įtaką diskusijos elgsenai bei šališkumui.

Literatūra ir šaltiniai

[Fir25] Firecrawl. *Best Web Search APIs for AI Applications in 2026*. 2025. URL: https://www.firecrawl.dev/blog/best-web-search-apis (žiūrėta 2026-04-10).

[GHT24] M. Geng, S. He, R. Trotta. „Are large language models chameleons? an attempt to simulate social surveys“. Iš: *arXiv preprint arXiv:2405.19323* (2024).

[Goo25] Google DeepMind. *Gemma 3 27B*. 2025. URL: https://deepmind.google/models/gemma/gemma-3/ (žiūrėta 2026-05-01).

[GXG+23] Y. Gao, Y. Xiong, X. Gao, K. Jia ir kiti. „Retrieval-augmented generation for large language models: A survey“. Iš: *arXiv preprint arXiv:2312.10997* 2 (2023), puslapis 1.

[KJA+24] D. Kumar, U. Jain, S. Agarwal, P. Harshangi. „Investigating Implicit Bias in Large Language Models: A Large-Scale Study of Over 50 LLMs“. Iš: *arXiv preprint arXiv:2410.12864* (2024).

[MAF+25] B. F. Maier, U. Aslak, L. Fiaschi, N. Rismal, K. Fletcher, C. C. Luhmann, R. Dow, K. Pappas, T. V. Wiecki. „LLMs Reproduce Human Purchase Intent via Semantic Similarity Elicitation of Likert Ratings“. Iš: *arXiv preprint arXiv:2510.08338* (2025).

[Met25] Meta. *Llama 4 Maverick*. 2025. URL: https://www.llama.com/models/llama-4/ (žiūrėta 2026-05-01).

[Ope] OpenRouter. *OpenRouter API Reference*. URL: https://openrouter.ai/docs/api/reference/overview (žiūrėta 2026-05-04).

[PC26] S. Parihar, L. Cheng. „Evaluating Social Bias in RAG Systems: When External Context Helps and Reasoning Hurts“. Iš: *arXiv preprint arXiv:2602.09442* (2026).

[PJL+25] S. Park, S. Jeon, C. Lee, S. Jeon, B.-S. Kim, J. Lee. „A Survey on Inference Engines for Large Language Models: Perspectives on Optimization and Efficiency“. Iš: *arXiv preprint arXiv:2505.01658* (2025).

[POC+23] J. S. Park, J. O'Brien, C. J. Cai, M. R. Morris, P. Liang, M. S. Bernstein. „Generative agents: Interactive simulacra of human behavior“. Iš: *Proceedings of the 36th annual acm symposium on user interface software and technology*. 2023, puslapiai 1–22.

[Pra] G. Prasad. *Comparing AI agent frameworks: CrewAI, LangGraph, and BeeAI*. URL: https://developer.ibm.com/articles/awb-comparing-ai-agent-frameworks-crewai-langgraph-and-beeai/ (žiūrėta 2025-10-20).

[PS24] F. Perez-Cruz, H. S. Shin. *Testing the cognitive limits of large language models*. Techninė ataskaita. Bank for International Settlements, 2024.

[Sen21] Sentence Transformers. *all-mpnet-base-v2*. 2021. URL: https://huggingface.co/sentence-transformers/all-mpnet-base-v2 (žiūrėta 2026-05-01).

[SJE14] F. Squazzoni, W. Jager, B. Edmonds. „Social simulation in the social sciences: A brief overview“. Iš: *Social Science Computer Review* 32.3 (2014), puslapiai 279–294.

[Tav] Tavily AI. *Tavily Search*. URL: https://docs.tavily.com/documentation/api-reference/endpoint/search (žiūrėta 2026-05-04).

[TDR+24] A. Taubenfeld, Y. Dover, R. Reichart, A. Goldstein. „Systematic biases in LLM simulations of debates“. Iš: *Proceedings of the 2024 conference on empirical methods in natural language processing*. 2024, puslapiai 251–267.

[WWJ+25] Q. Wang, J. Wu, Z. Jiang, Z. Tang, B. Luo, N. Chen, W. Chen, B. He. „LLM-based Human Simulations Have Not Yet Been Reliable“. Iš: *arXiv preprint arXiv:2501.08579* (2025).

[ZKW+19] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, Y. Artzi. „Bertscore: Evaluating text generation with bert“. Iš: *arXiv preprint arXiv:1904.09675* (2019).

1 priedas. Programos kodas

Programos kodas pateikiamas *„GitHub“* saugykloje:
`https://github.com/TheMisterS/course_work-LLM-Society-`